分类号：TP301
密　级：公开
单位代码：10422
学　　号：202237785

山东大学
SHANDONG UNIVERSITY

硕士学位论文

Thesis for Master Degree
（专业学位）

论文题目：融合模型与大语言模型协同优化的专利自动分类方法及系统的研究

Research on patent automatic classification method and system based on collaborative optimization of fusion model and large language model

作者姓名　刘明珠
培养单位　数学与统计学院
专业学位名称　应用统计
指导教师　郭亮 教授
合作导师

2025 年 5 月 22 日

中国知网 https://www.cnki.net

摘要

在知识经济时代，技术创新和知识产权的保护对企业的竞争力和持续发展至关重要。在众多的专利中，有大量的信息和技术被记录和保护。通过对这些专利进行分析，可以发现技术领域的发展趋势、核心技术的演进路径、技术和市场的关联性以及市场竞争格局等。

专利分类指对不同类型的发明和创新进行系统的组织和管理。它有助于提供更清晰、更有序的专利数据库，并使人们能够更方便地搜索、了解和利用相关的技术信息。专利分类的意义在于组织和整理知识、提供检索和搜索便利、促进技术交流和合作、辅助决策和研究以及加强知识产权保护。通过分类，可以使专利信息更有序、更易获取，为人们的创新活动和知识应用提供有力的支持和指导。这些分析和分类结果对于科学研究人员、企业战略决策者和投资者等都具有重要参考价值。

本文主要从专利数量类、专利质量类和专利价值类三个评价指标的角度对已知的专利数据进行深入的数据挖掘和可视化分析。数量类主要包括专利类型、专利申请量和申请趋势等方面，质量类则涉及 IPC 分类和洛迦诺分类等分类标准，而价值类则关注专利权人和专利地域表现等因素。本文通过对这三个评价指标的深入综合分析来揭示我国目前专利的发展状况和科技创新的能力，为提升自主创新能力和进行专利布局提供一定的参考。

目前，中国专利文本分类主要依赖于领域内专家人工标注，辅以半自动化技术。然而，现有方法在工程化应用层面仍存在显著技术壁垒，难以支撑海量专利数据的全流程自动化处理需求。因此，探讨如何有效实现专利文本的自动分类并搭建智能化分类系统具有极为重要的现实意义和挑战性。

本文基于以上背景以及分析主要实现了三种中国专利文本自动化分类的技术路线：

第一，基于 BERT 和 ERNIE 的文本分类模型：本文基于模型融合原理，分别将预训练语言模型 BERT 和 ERNIE 与深度学习模型 TextCNN、TextRNN、TextRCNN、DPCNN 融合，搭建了八种新的文本分类模型，并在开源数据集 THUCNews 上验证了所构建模型在文本分类上的有效性；

第二，基于 DeepSeek-V3 的文本分类模型：本文在大语言模型 DeepSeek-V3 的基础上，结合指令工程（Prompt Engineering）设计清晰的提示词（Prompt），实现了高效的文本自动分类；

第三，基于 LangChain 的文本自动分类模型：本文采用框架级方案 LangChain 集成管理大语言模型 DeepSeek-V3，通过任务流程模块化编排实现了文本自动化分类；

中国知网 https://www.cnki.net

最后，本文基于以上三种技术方案设计并部署了中国专利文本智能分类系统，其中系统亦增设了专利关键词自动提取模块。

关键词：专利分类；自然语言处理；ERNIE；BERT；DeepSeek；LangChain

中国知网 https://www.cnki.net

ABSTRACT

In the era of knowledge economy, technological innovation and the protection of intellectual property rights are crucial to the competitiveness and sustainable development of enterprises. Among the numerous patents, a large amount of information and technologies are recorded and protected. By analyzing these patents, it is possible to find out the development trend of the technological field, the evolution path of the core technology, the correlation between technology and market, and the market competition pattern.

Patent classification refers to the systematic organization and management of different types of inventions and innovations. It helps to provide a clearer and more organized patent database and enables people to search, understand and utilize relevant technical information more easily. The significance of patent classification lies in organizing and structuring knowledge, providing search and retrieval facilities, promoting technological exchange and cooperation, aiding decision-making and research, and strengthening intellectual property protection. Through classification, patent information can be made more organized and accessible, providing strong support and guidance for people's innovative activities and knowledge application. The results of these analyses and classifications have important reference value for scientific researchers, corporate strategic decision makers and investors, etc.

This paper focuses on in-depth data mining and visualization analysis of known patent data from the perspectives of three evaluation indexes: patent quantity category, patent quality category and patent value category. The quantity category mainly includes patent types, patent applications and application trends, while the quality category involves classification standards such as IPC classification and Locarno classification, and the value category focuses on factors such as patentees and geographical performance of patents. This paper reveals China's current state of patent development and scientific and technological innovation ability through an in-depth comprehensive analysis of these three evaluation indicators, providing certain reference for enhancing independent innovation ability and patent layout.

At present, China's patent text classification mainly relies on manual annotation by experts in the field, supplemented by semi-automated technology. However, the existing methods still have significant technical barriers at the level of engineering application, and it is difficult to support the demand for full-process automated processing of massive patent data. Therefore, it

中国知网 https://www.cnki.net

is of great practical significance and challenge to explore how to effectively realize automatic classification of patent text and build an intelligent classification system.

Based on the above background and analysis, this paper mainly realizes three technical routes for automatic classification of Chinese patent text:

First, text classification model based on BERT and ERNIE: Based on the principle of model fusion, this paper fuses the pre-trained language models BERT and ERNIE with the deep learning models TextCNN, TextRNN, TextRCNN, and DPCNN, and builds eight new text classification models, which are based on the principle of model fusion and the deep learning models TextCNN, TextRNN, TextRCNN and DPCNN. Eight new text categorization models are built, and the effectiveness of the constructed models in text categorization is verified on the open source dataset THUCNews;

Second, text categorization model based on DeepSeek-V3: Based on the large language model DeepSeek-V3, this paper combines with Prompt Engineering to design clear prompt words (Prompt), and realizes the text categorization model with the deep learning model BERT and ERNIE, and the deep learning model TextCNN, TextRNN, TextRCNN, and DPCNN. (Prompt), which realizes efficient automatic text classification;

Third, text automatic classification model based on LangChain: this paper adopts the framework-level scheme LangChain to integrate and manage the large language model DeepSeek-V3, and realizes automatic text classification through the modular arrangement of the task flow;

Lastly, based on the above three technological solutions, this paper designs and deploys a Finally, based on the above three technical solutions, this paper designs and deploys a patent text intelligent classification system in China, in which a patent keyword automatic extraction module is also added to the system.

Key words: Automatic Patent Classification; Natural Language Processing; ERNIE; BERT; DeepSeek; LangChain

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景及意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....2
1.2 国内外研究现状.....2
1.2.1 专利分析.....2
1.2.2 专利文本数据分类.....3
1.2.3 自然语言处理在文本分类中的应用.....3
1.3 研究内容和组织结构.....4
1.3.1 主要研究内容.....4
1.3.2 论文组织结构.....5
2 专利数据分析的相关理论与技术概述.....7
2.1 文本分类相关理论与技术.....7
2.1.1 中文分词.....7
2.1.2 去停用词.....7
2.1.3 文本向量化.....8
2.1.4 提示词工程.....9
2.1.5 LangChain.....10
2.2 自然语言处理相关理论与技术.....10
2.2.1 TextCNN.....10
2.2.2 TextRNN.....11
2.2.3 TextRCNN.....11
2.2.4 DPCNN.....12
2.2.5 Transformer.....13
2.2.6 BERT.....15
2.2.7 ERNIE.....16
2.2.8 DeepSeek.....17
3 中国专利数据的分析研究.....18
3.1 专利数据介绍.....18
3.2 专利文本数据的相关可视化分析.....19
3.2.1 专利数量类评价.....19
3.2.2 专利价值类评价.....20
3.2.2 专利质量类评价.....23
4 文本自动分类模型的设计与实验.....26

中国知网　https://www.cnki.net

4.1 文本自动分类模型的设计 26
4.2 文本自动分类模型的实验 28
4.2.1 实验数据 28
4.2.2 实验设计 29
4.3 实验结果分析 30
5 基于自然语言处理的专利文本自动分类系统 33
5.1 专利文本分类方案的实验 33
5.1.1 基于 BERT 和 ERNIE 的文本分类模型实验 33
5.1.2 基于 DeepSeek-V3 的文本分类模型实验 36
5.1.3 基于 LangChain 的文本分类模型实验 37
5.1.4 专利文本关键词提取的实验 37
5.2 专利文本自动分类系统的设计 38
5.3 专利文本自动分类系统的测试 38
5.3.1 专利文本自动分类系统的前端网页界面 38
5.3.2 专利文本自动分类系统的测试 39
6 总结与展望 42
6.1 工作总结 42
6.2 未来展望 43
参考文献 45

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景及意义

1.1.1 研究背景

随着知识经济时代的迅速来临，整个社会的转型和变革速度和范围都比以往更快更广。科学技术呈现在创新规模和创新速度的双重跃升。与此同时，科技成果产业化转化效率的显著提升，科技产品生命周期显著缩短，市场竞争日益激烈。在技术迭代加速与市场竞争加剧的双重压力下，企业技术创新能力已成为决定其生存与发展空间的核心要素。[1] 因此，明确当前发展路径与未来演进方向，不仅需要系统性评估现有风险，更需构建适应性治理框架，以应对不断变化的内外部环境。[2]

作为科技创新成果的核心载体，专利技术在推动社会生产力发展和技术进步中发挥着不可替代的作用。专利制度通过法律框架为发明创造提供保护机制，同时激励技术创新的持续涌现。[3] 在全球竞争格局中，知识产权战略已成为企业构建核心竞争力的关键要素，其通过专利布局与技术壁垒的建立，为市场主体提供了差异化的竞争优势。[4]分析专利信息以制定和实施专利战略，是至关重要且不可或缺的一环。

专利分析的核心在于对专利说明书、公报等文献信息进行系统性采集与深度挖掘。通过多维度数据整合与结构化处理，结合统计建模与量化分析方法，将原始专利信息转化为具有战略价值的竞争情报，这一系列活动为企业在技术、产品、决策等方面提供一定的参考。[5]

随着企业中专利数量的不断增多以及专利工作的深入发展，专利分类分级化管理[6]逐渐受到重视，这项工作是专利申请、维护等重要管理工作的升级版，也是主动开展运用和保护工作的迫切要求。

专利可以按照多种维度进行分类管理。在知识产权维度下，可以按照专利、商标、版权进行分类管理；在专利维度下，可以按照不同申请国家、不同专利类型进行分类管理；还可以根据各种属性特征进行更为精细的分类，如专利的技术领域，对应的产品，产出部门等。与此同时，还可以采用不同的管理方式，如规定不同的责任主体、设定不同的工作目标、采用不同的工作流程等。[7]

与分类管理相比，分级化管理更为复杂和精细。它根据专利的价值对专利进行分级，以确定资源投入、管理流程和运营模式等方面的级别。[8]其主要目标是提升专利管理效率，降低管理成本，持续优化企业的专利资产。它的关键在于评估专利价值并建立分级

中国知网 https://www.cnki.net

标准。

1.1.2 研究意义

随着当前知识产权意识的提升以及知识产权强国建设计划的不断推进，中国的专利数量呈现显著的上升趋势。[9] 这一现象不仅体现了国家科技创新能力的整体跃升，也对专利管理体系的专业化水平提出了更高要求。作为专利信息管理的核心技术手段，分类系统的优化与升级成为应对海量数据处理挑战的关键突破口。[10] 面对专利文献规模的指数级扩张，传统人工分类模式已难以满足高效检索与深度分析的需求，亟需构建智能化分类体系以提升专利信息处理的效率与准确性。[11]

在专利的检索、专利的捆绑、专利的挖掘以及其他信息的利用中，专利分类作为专利文本研究和应用的基础工作扮演着十分关键的角色。[12]

专利文本分类是指根据专利文本中包含的技术信息内容的要点，在给定的分类系统（例如 IPC 分类系统[13]）中确定专利所属类别的过程。

传统的专利文本分类通常采用人工分类的方式，即专业分类人员需根据自身专业知识，阅读专利文本后，手动设定类别，为文本分配一个或多个分类符号，以实现分类的目的。传统分类模式在实践应用中暴露出显著的效率瓶颈与质量隐患。具体而言，其分类周期较长、资源投入成本较高、处理效率偏低，且高度依赖领域专家的参与。更为重要的是，分类过程易受主观判断与外部环境等多重因素的干扰，导致分类结果的一致性与可靠性难以保证。专利文本分类效率低下，导致专利信息的获取和利用困难。[14]不同分类结果使得专利信息更难被提取，这反过来又可能导致科学和技术决策过程中的严重错误。因此，研究能够解决上述问题的专利文本分类新方法是非常必要的。

综合以上所述，随着人工智能技术的快速发展，采用先进的智能技术进行专利自动化分类具有重要的现实意义，它有助于减轻专利分类工作的负担，提升分类的效率。

1.2 国内外研究现状

1.2.1 专利分析

在 1474 年之前，世界迎来了首部专利法，至今已历经五个多世纪的演进与完善。当下，全球专利数量约为 6000 万件，每年还会新增约 150 万件专利文献。[15]

在科技创新驱动与市场竞争加剧的双重作用下，专利信息作为战略资源的价值认知度显著提升。通过系统性采集与深度挖掘专利数据，构建基于大数据的竞争情报分析体系，已成为把握技术演进规律与市场动态的重要途径。[16]当前，专利分析技术正经历从传统手工模式向智能化处理的范式转型，其发展方向呈现出自动化程度提升、功能模块

中国知网 https://www.cnki.net

优化与可视化效果增强的三维特征，这标志着专利分析进入了效率与精度并重的新阶段。[17]

专利分析常用的方法包括统计频率分类法、三角分析法和时间序列分析法。在这些方法中，统计和频率分类分析是关键任务之一。[18]当我们对在进行专利的一些信息展开分析时，首要的步骤就是根据专利分类号以及申请人等特征进行检索，然后根据特定要求将检索结果进行升序或降序排列，以便更清晰地展示相关信息。这种方法能全面呈现专利中的技术、经济和法律信息。时间序列分析是一种简单且广泛应用的定量分析方法，通过检查统计数据随时间变化的模式，预测未来变化趋势。[19]举例来说，通过绘制公司在特定专利分类下随时间的专利数量变化情况图，可以分析该公司在特定技术领域的参与与退出趋势。通过三角分析法[20]，将特定技术领域发明、实用新型专利、工业品外观设计专利以及商标的年度申请量进行横向对比与纵向趋势研究，并将它们按时间顺序有机地联系起来。这种方法有助于更全面地了解各类专利申请的趋势和关联性。

1.2.2 专利文本数据分类

专利文本分类体系的核心在于依据特定规则、元数据特征及文本语义信息等多维度指标，实现专利分类号的精准分配。[21]这种分类方法能够有效地帮助研究人员快速准确地了解专利的主题和内容，提高专利信息检索的效率。[17]由于专利文件一般具备比较格式化的写作结构，所以基于此类文本内容实现自动分类可以得到较好的分类结果。

专利分为发明专利、实用新型专利和外观设计专利三大类型。[22]就发明和实用新型专利而言，国际上主要的专利分类体系包括国际专利分类体系（IPC）、日本专利分类体系（FI/F-term）[23]、美国专利分类体系（USPC）[24]、欧洲专利分类体系（ECLA/ICO）[25]以及联合专利分类（CPC）[26]。

在2014年7月之前，专利分类工作主要依托于国际专利分类体系（IPC），由国家知识产权局的分类部门统一负责发明与实用新型专利的分类管理。[27]从2014年8月起，分类体系改革进入试点阶段，在特定技术领域的新公开发明案件中首次引入 CPC 分类体系。[27]随着 2015 年试点领域范围的扩大，对这些领域的新公开发明案件和新申请发明案件也开始进行 CPC 分类。[28]到了 2016 年，对所有新申请发明案件都会进行 CPC 分类，因此，自 2016 年起，国家知识产权局处理的每一份新申请发明案件都会同时标引 IPC 分类号和 CPC 分类号。[29]

1.2.3 自然语言处理在文本分类中的应用

从1960年到2010年，以浅层学习为代表的文本分类模型一直占据主导地位。[30]这里的浅层学习是指基于统计方法的模型，例如朴素贝叶斯方法（NaïveBayes，NB）[31]、K 近邻（K- Nearest Neighbor，KNN）[32]和支持向量机（Support Vector Machine，SVM）

中国知网 https://www.cnki.net

[33]。这些技术在数据的准确性和稳定性等方面明显优于早期基于规则的方法。尽管如此，这些技术仍需进行繁琐的特征工程，这会消耗大量时间和精力。此外，这些方法主要问题在于未充分考虑文本数据的序列依赖性与上下文关联信息，这就使得制约了模型对词汇间语义关系的捕捉能力。[34]

随着时代的发展，尤其是进入 2010 年后，文本分类技术正在经历从浅层学习范式向深度学习范式的系统性转型。[35]深度学习方法对比于之前的浅层的学习方法具有非常明显的优点，因为它们不需要人工花费时间和精力设计规则和特征，而是能够自动从文本中提取丰富且大量的语义表示。因此，大多数文本分类研究工作都是基于数据驱动且计算复杂度较高的 DNNs[36]来进行的。

这些基于深度神经网络的文本分类方法大部分主要依托于卷积神经网络（Convolutional Neural Network，CNN）[36]、循环神经网络（Recurrent Neural Network，RNN）[37]和注意力机制等深度学习技术。其中，双向编码器表示（BERT）[38]的提出被视为文本分类和其他自然语言处理（NLP）技术的重要里程碑。研究人员们已经进行了许多基于 BERT 的文本分类模型研究工作，研究结果表明，该模型在多个 NLP 任务中表现出比之前模型更显著的应用潜力，其中包括文本分类。[30]近年来，图卷积网络（Graph Convolutional Network，GCN）[39]、区域嵌入以及元学习等新兴方法也在文本分类领域展现出显著的应用潜力，进一步拓展了深度学习在文本分析中的技术边界。

近年来，大语言模型（Large Language Models, LLMs）[40]在文本分类领域的发展迅速推动了自然语言处理技术的革新。随着深度学习技术的兴起，以 RNN 和 CNN 为代表的神经网络提升了上下文建模能力，但仍需大量标注数据来支持。伴随着自注意力机制等技术的发展，以 BERT 和 ERNIE[41]为代表的预训练语言模型彻底改变了这一局面。通过在大规模无标注语料库上进行自监督预训练（如掩码语言建模、下一句预测），模型能够学习深层次的语义和语法知识，并可通过微调（Fine-tuning）快速适配下游分类任务，显著降低了对标注数据的依赖。[42]这一类预训练语言模型在上下文理解任务中表现优异，但是它的生成能力很有限。而以 GPT（Generative Pre-trained Transformer）[43]和 DeepSeek[44]为代表的大语言模型在各种多模态复杂任务中占据显著的优势。

1.3 研究内容和组织结构

1.3.1 主要研究内容

本文主要基于自然语言处理技术，对中国专利文本数据进行自动化分类。

首先，对专利文本从数量类、质量类和价值类三个维度进行可视化数据分析；

其次，实现了三种文本分类的技术方案：第一，基于 BERT 和 ERNIE 的文本分类

中国知网 https://www.cnki.net

模型：本文基于模型融合原理，分别将预训练语言模型 BERT 和 ERNIE 与深度学习模型 TextCNN、TextRNN、TextRCNN、DPCNN 融合，搭建了八种新的文本分类模型，并在开源数据集 THUCNews 上验证了所构建模型在文本分类上的有效性；第二，基于 DeepSeek-V3 的文本分类模型：本文在大语言模型 DeepSeek-V3 的基础上，结合指令工程（Prompt Engineering）设计清晰的提示词（Prompt），实现了高效的文本自动分类；第三，基于 LangChain 的文本自动分类模型：本文采用框架级方案 LangChain 集成管理大语言模型 DeepSeek-V3，通过任务流程模块化编排实现了文本自动化分类；

最后，本文基于以上三种技术方案设计并部署了中国专利文本智能分类系统，其中系统亦增设了专利关键词自动提取模块。

1.3.2 论文组织结构

本文各章节主要内容如下：

第一章：首先阐述专利分析的研究背景和意义；其次介绍专利分析、专利文本数据分类体系以及基于自然语言处理的文本分类的主要相关技术在国内外的研究现状；最后总体呈现展示本文的主要研究内容以及论文的组织结构。

第二章：介绍专利分类的相关理论和关键技术。主要包括文本分类以及基于深度学习的自然语言处理模型的相关理论技术和概述。在文本分类中，介绍中文分词、去停用词、文本向量化和提示词工程四个方面；在基于深度学习的自然语言处理模型中，介绍了 TextCNN、TextRNN、TextRCNN、DPCNN、Transformer、BERT、ERNIE、DeepSeek 等模型以及 LangChain 框架。

第三章：进行专利数据的分析研究。首先，详细介绍专利的类型以及在此基础上的两种专利分类体系：在发明专利和实用新型专利中介绍了国际专利分类体系（IPC）；在外观设计专利中介绍了洛迦诺分类体系。其次，实现对专利数据的可视化分析：从质量类、数量类和价值类三个维度对中国专利数据进行图表可视化并对相关内容展开详细分析。

第四章：进行文本自动分类模型的设计与实验。基于模型融合原理，分别将预训练语言模型 BERT 和 ERNIE 与深度学习模型 TextCNN、TextRNN、TextRCNN、DPCNN 融合，构建八种新的文本分类模型，并在在开源文本分类数据集 THUCNews 上完成新闻标题的十分类实验，实验结果验证所设计模型的有效性。

第五章：进行专利自动分类模型的设计与实验。第一，基于前文构建的文本分类模型实现专利文本分类；第二，基于大语言模型 DeepSeek-V3，结合指令工程（Prompt Engineering）设计清晰的提示词（Prompt），实现高效的专利文本分类；第三，基于框架级方案 LangChain，集成管理大语言模型 DeepSeek-V3，通过任务流程模块化编排实

中国知网 https://www.cnki.net

现专利文本分类；最后，使用 Python 开源库 Gradio 完成基于以上三种技术方案的中国专利文本分类系统的设计和部署，其中系统亦增设了专利关键词自动提取模块。

第六章：对全文进行总结和归纳，并结合在研究过程中所遇到的问题进行分析，最后对未来研究方向做出了展望。

中国知网 https://www.cnki.net

2 专利数据分析的相关理论与技术概述

2.1 文本分类相关理论与技术

2.1.1 中文分词

中文分词是指在中文句子中为词与词之间加上边界来进行标记的过程[45]。中文分词技术体系主要包含基于规则、统计和深度学习的三类方法。具体而言，基于规则的方法主要采用最短路径算法与字构词策略；统计方法则以 n 元语法模型为代表；而深度学习方法则依托循环神经网络（RNN）与 Transformer 架构。

最短路径分词指的是在词图上选择一条最短的路径；n 元语法分词通过在词图上选择概率最大的路径来确定分词结果；而由字构词的核心概念是每个字在构造一个词语时都有一个固定的构词位置，也称为构词位；循环神经网络分词运用长短期记忆模型（Long short-term memory, LSTM）[46]，重点关注词与词的前后关系；2014 年，Google 在 *Recurrent Models of Visual Attention*[47]论文中提出 Attention 机制。2017 年，Google 在 *Attention is All You Need* 论文中首次提出了 Transformer 模型，而 Transformer 分词的主要思想则是关注重点。

目前，中文分词的实用工具也有很多，关注度较高的有 jieba、HanLP、FoolNLTK 等。Jieba 运用的中文分词方法是由字构词，其原理是采用隐马尔可夫模型和字典。HanLP 是依据条件随机场（Conditional Random Field，CRF）[48] 来实现的，它是自然语言处理的核心基本模型之一，目前已被广泛应用到中文分词、命名实体识别以及词性标注等标注场景中。FoolNLTK 的分词方法是循环神经网络分词。

总的来说，对于基于规则的中文分词来说，它忽略了上下文语境；对于基于统计的中文分词来说，这里的统计是频率和概率关系，并不是因果关系；对于基于深度学习的中文分词来说，深度学习却是一个“灰箱”，我们并不知道在箱子中到底发生了什么。[49]

2.1.2 去停用词

在定位中文单词时，句子中出现的单词会被分开，有些单词没有实际意义，这会增加后续关键字提取的负载，可能会使提取的关键字无效。因此，在分词之后，我们将去除停用词来优化分词的结果。[50]

在中文文本的处理中，去除停用词的常用方法主要有两种：

中国知网 https://www.cnki.net

使用固定的停用词表：可以事先准备一个包含常见停用词的列表，然后将这些停用词从文本中去除。中文停用词表[51]常用的主要有：中文停用词表、哈工大停用词表和百度停用词表。同时，可以根据需求和语料库的特点来扩充停用词表，例如可以考虑添加一些领域特定的停用词。通过遍历文本，将出现在停用词表中的词语删除，即可实现停用词的去除。

基于统计的方法：这种方法是根据文本中词语的频率来判断是否为停用词。可以通过统计整个语料库中各个词语的出现频率，并设定一个阈值。超过该阈值的词语被认为是停用词，可以进行去除。这种方法能够根据具体语料的特点自适应地确定停用词，因此相对较为灵活。[52]

2.1.3 文本向量化

文本向量化作为自然语言处理的关键预处理步骤，其核心在于将非结构化的文本数据转化为结构化的数值表示形式。[53] 以下将系统介绍几种主流的文本向量化技术及其应用场景：

One-Hot 编码[54]：这一方法是将每个词汇映射为独一无二的整数索引，接着用由 0 和 1 组成的向量来表示每个词汇，其中只有对应索引位置的值为 1，其余位置为 0。这种表示方式可以保留词语的出现与否信息，但没有考虑词语之间的关系。这种方法简单直观，易于理解和实现。缺点是向量维度较高，且无法表达词语之间的关系，没有考虑到语义信息。

词袋模型（Bag-of-Words）[55]：它将文本当成是一个袋子里的词语集合，忽略词语在句子中的顺序，只考虑词语的出现频率。首先建立一个词汇表，然后统计每个词语在文本中的出现次数或者使用词频（Term Frequency, TF）。最终得到一个高维的向量表示，其中每个维度对应一个词语。这种方法考虑了词语的出现频率，简单有效，但是忽略了词语的顺序和上下文信息，无法捕捉词语的语义含义，容易出现维度灾难问题。

TF-IDF（Term Frequency-Inverse Document Frequency）[56]：它是在词袋模型的基础上引入权重的一种方法。除了考虑词语在文本中的词频，还考虑了词语在整个语料库中的重要性。TF-IDF 值由词频（TF）和逆文档频率（IDF）两部分组成，其中 IDF 可以衡量一个词语对于整个语料库的重要程度。最终得到一个考虑了词频和重要性的向量表示。这种方法考虑了词语在整个语料库中的重要性，能够突出一些特定词语的重要程度，但是仅考虑了词频和逆文档频率，无法捕捉词语之间的顺序和上下文关系。

Word2Vec[57]：其核心在于通过神经网络架构将离散的词语映射到连续的向量空间。Word2Vec 能够捕捉词语之间的语义关系，例如单词之间的相似性和关联性。通过训练后得到的词向量可以作为文本的向量表示。这种表示方式能够将词语映射到连续向量空

中国知网 https://www.cnki.net

间中，捕捉词语的语义关系和上下文信息。缺点是对于少见词语和新词可能表现不佳，需要大规模语料进行训练。

BERT（Bidirectional Encoder Representations from Transformers）：该文本向量化方法依托 Transformer 模型架构，已经被广泛应用于各种自然语言处理任务中。[58]与传统的词袋模型或者 Word2Vec 方法不同，BERT 能够同时考虑上下文信息，具有更强的语义理解能力。但是 BERT 在实际应用中计算复杂度高，模型非常大，所以需要大量的训练数据和计算资源。

通常需要根据具体的任务和场景选择合适的文本向量化方法。例如，对于简单的分类任务，词袋模型或 TF-IDF 可能已经足够，而对于更复杂的语义理解任务，Word2Vec 或 BERT 可能更加适用。此外，还可以结合多种方法，比如可以利用特征工程、降维[59]等技术进行优化和改进。

2.1.4 提示词工程

在大语言模型（LLM）应用和优化阶段中，提示词工程（Prompt Engineering）是其中一个极其重要的方法。[60]提示词工程（Prompt Engineering），也称为指令工程，通过结构化输入指令设计实现对模型生成行为的精确控制[61]，主要方法如下：

零样本学习（Zero-Shot）：基于 LLMs 的泛化能力，通过自然语言指令直接指定任务目标。零样本学习通过自然语言的任务描述激活模型预训练阶段获得的隐含知识映射能力[62]，其数学表达可形式化为：

$$P(y|x) = \prod_{t=1}^{T} P(w_t|x, w_{<t}) \tag{2-1}$$

其中x为包含任务描述的提示词，y为目标输出序列。模型通过注意力机制计算 Token 间的关联权重，实现跨领域知识迁移。

少样本学习（Few-Shot）：通过提供少量标注样本建立任务范式，激活模型的类比推理能力，模型通过交叉注意力计算输入与范例的语义相似度矩阵[63]：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)\text{V} \tag{2-2}$$

其中Q为当前输入向量，K和V为范例存储矩阵。

思维链（Chain-of-Thought）：通过分步推理提示（Step-by-Step Reasoning）引导模

中国知网 https://www.cnki.net

型生成中间推导过程[64]，其数据流可建模为：

$$\text{Reasoning Path} = \bigcup_{i=1}^{n} \{ r_i \mid r_i = f_\theta(x, r_{<i}) \} \quad (2-3)$$

其中r_i为第 i 步推理状态，f_θ为模型参数化的推理函数。

指令调优（Instruction Tuning）：主要通过监督微调、奖励建模、强化学习三阶段来进行调优[65]。

2.1.5 LangChain

LangChain 是由语言模型驱动的任务流程模块化编排的框架级方案，它提供了一套模块化工具和抽象层，能够更高效地集成和管理语言模型。[66]相比传统的使用大量已标注的数据来训练模型以及耗费大量 Token 直接调用大语言模型这两种方案来说，LangChain 是一次平衡成本与效果来解决复杂语言问题的系统级优化方案。[67]

传统的语言模型虽然在特定任务上的精准度高，但是它的标签固定，同时往往需要大量的已标注好的训练数据来训练，并且它及其依赖训练数据的质量和规模，训练成本需求非常高；[68]大语言模型则可以通过灵活改变提示词，动态调整分类规则，并且它对训练样本的需求低，但是这种直接调用的方式依赖大模型的规模，输出不稳定，同时需要按照 Token 来付费。[69]

LangChain 则是协调整合大语言模型 API、传统模型、工具链和外部数据的框架级方案。[70]它通过标准化接口和功能模块，能够高效利用大语言模型，尤其适合需要多工具协作、长期记忆或复杂工作流的场景，其核心价值在于将 LLM 从“文本生成器”升级为“智能应用引擎”。[71]

2.2 自然语言处理相关理论与技术

2.2.1 TextCNN

Yoon Kim 在论文 *Convolutional Neural Networks for Sentence Classification* 中第一次提出了 TextCNN[72]。当需要对文本进行分类时，如果依赖卷积神经网络 CNN，那我们可以通过采用多个不同尺寸的卷积核来提取句子的关键信息。这类似于采用多种窗口大小的 N-gram，有助于更有效地捕捉局部相关性。在模型架构层面，TextCNN 与传统的图像卷积神经网络（CNN）保持了高度一致性，其核心结构仅包含单层卷积操作与最大池化层，根据下图 1 可见，TextCNN 最终通过 Softmax 实现多分类。[72]

中国知网 https://www.cnki.net

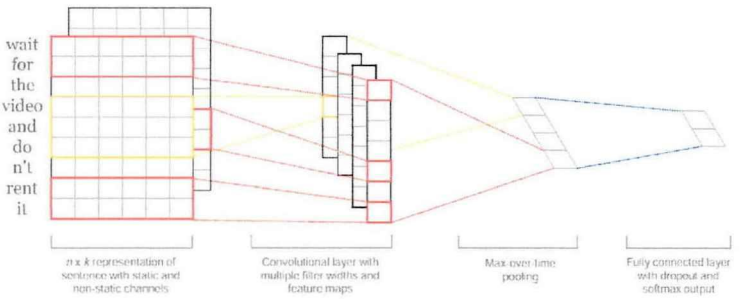


图 1 TextCNN 模型架构[72]

2.2.2 TextRNN

在进行文本分类任务时，利用 RNN 的一个基本方法是将序列映射到固定维度的向量，然后通过 Softmax 全连接层进行文本分类。为了对给定的文本序列进行处理，首先需要使用嵌入层来获取每个词的表示，接着将最后一个时间步的输出传递至全连接层，以预测类别概率。[34]具体的 RNN 文本分类模型架构可参考下图 2 所示。

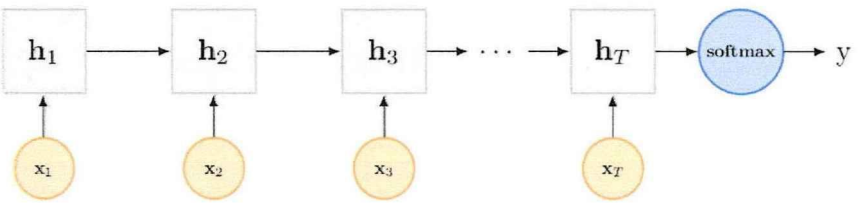


图 2 TextRNN 模型架构[73]

2.2.3 TextRCNN

该模型分为三部分：R-CNN[74]结构，池化层和输出层。模型架构如下图 3 所示。R-CNN 部分是一个双向的循环神经网络，输入是单词的 Embedding，第 i 个位置的隐藏状态受到它的左右两边的上下文的影响，R-CNN 的输出结构再接入 Max-pooling 和 Softmax 层，其最后的输出就是文本的分类结果。[75]

由于文本本身的特点，CNN 作为一个固定的窗口大小，文本的所有信息很难被其完全采集到，而 RNN 由于当前的状态会容易受到上下文的影响，因此模型在学习的时候自然会考虑到文本的上下文的影响，而且它影响的范围大于 CNN 的卷积核，因此，一

中国知网 https://www.cnki.net

般来说，RNN 的效果要优于 CNN 的效果。[75]

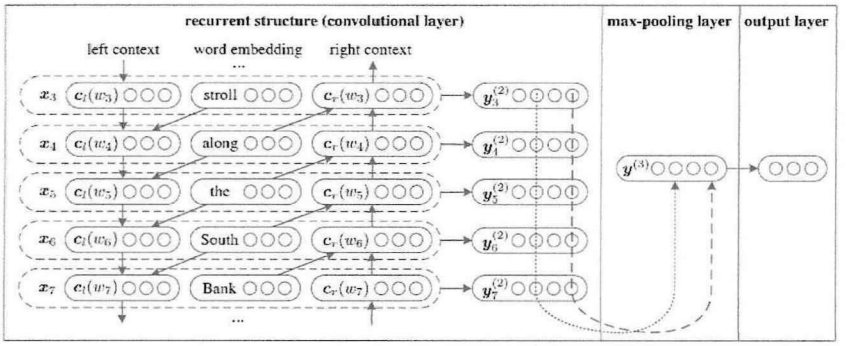


图 3 TextRCNN 模型架构[75]

2.2.4 DPCNN

腾讯 AI_LAB 在 2017 年的 ACL 上发表了 *Deep Pyramid Convolutional Neural Networks for Text Categorization*[76]，提出了一种深层次的 CNN 文本分类模型。由于卷积层的堆叠方式看起来像金字塔，所以称之为 Deep Pyramid CNN。[76]该模型架构如图 4 所示。

相比 TextCNN，DPCNN 通过使用下采样和等长卷积，提取到了词汇更长距离的依赖。通过使用残差连接，DPCNN 大大增加了模型的深度，使模型可以提取到更加抽象的特征。

中国知网 https://www.cnki.net

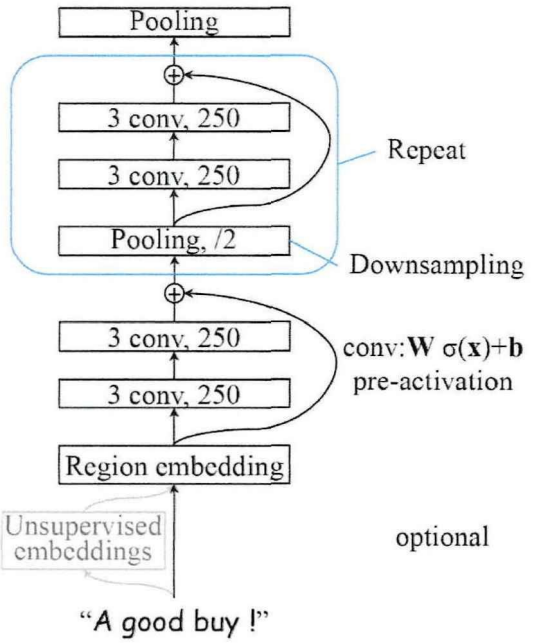


图 4 TextRCNN 模型架构[76]

2.2.5 Transformer

深度学习模型 Transformer 采用了注意力机制，最初主要用于自然语言处理任务，但现在也逐渐被应用在其他领域。Transformer 模型的设计结构使得它能够有效地处理长距离依赖关系，在能力上超越了传统循环神经网络 RNN。在处理长序列数据时，传统的循环神经网络 RNN 存在梯度消失以及爆炸的挑战和问题，而 Transformer 通过引入自注意力机制来解决了这个问题。它不需要按顺序处理序列数据，而是同时对整个序列进行编码和解码，并且可以利用并行计算能力提升训练速度。[77]

Transformer 包含 Encoder 和 Decoder 两个部分，每个部分均由 6 个 Block 组成。[77]Transformer 的模型架构如图 5 所示。

中国知网 https://www.cnki.net

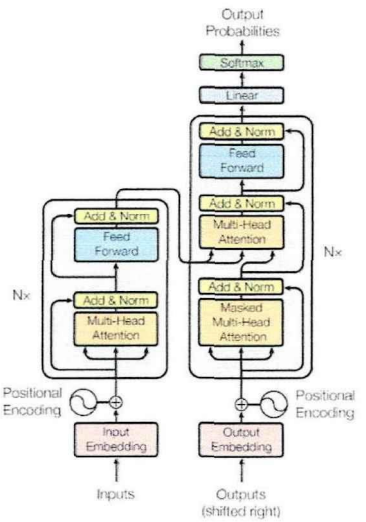


图 5 Transformer 模型架构[77]

在图 5 的结构中，Encoder block 位于左侧，而 Decoder block 位于结构的右侧。Multi-Head Attention 由多个 Self-Attention 并行组成。从图中可以看出，Encoder block 包含一个 Multi-Head Attention，而 Decoder block 配置了两个 Multi-Head Attention，其中一个带有 Masked 组块。[77]在 Multi-Head Attention 上方，设有一个 Add & Norm 层，Add 用于残差连接，缓解梯度消失问题，Norm 用于对激活值进行归一化。[77]在 Transformer 中，词的输入是通过词 Embedding 和位置 Embedding 相加得到的。将得到的句子的词表示向量矩阵传入 Encoder，经过 6 个 Encoder block 的逐层处理，最终输出包含句子全部语义信息的编码矩阵。[78]将 Encoder 输出的编码信息矩阵传递到 Decoder，Decoder 会逐步处理数据，在该过程中需要通过 Mask 操作遮盖未处理的数据。在模型训练时，Decoder block 第二个 Multi-Head Attention 的输入是由 Encoder 的编码信息矩阵计算得到的。[77]

通常，Transformer 模型的训练过程一般可分为模型预训练和模型微调两个阶段。预训练阶段通过大规模无监督语料库进行语言建模任务，旨在优化模型参数的初始化状态。[79]而在微调阶段通过在特定任务的有监督数据集上进行训练，实现对预训练模型的参数优化与任务适配。[77]

Transformer 在机器翻译、文本摘要、问答系统和语言生成等自然语言处理任务中取得了显著的成果，并且也被应用在计算机视觉领域中，如图像生成和目标检测等任务。其优势在于能够处理长序列依赖关系、并行计算能力强和表达能力强等特点，成为现代深度学习中的重要模型之一。[80]

中国知网 https://www.cnki.net

2.2.6 BERT

基于Transformer模型的预训练语言模型BERT（Bidirectional Encoder Representations from Transformers）被视为自然语言处理领域的重大进展之一。[38]

BERT的主要思想就是通过无监督的方式，通过在大规模文本语料库上进行预训练，使模型能够学习到深层次的语义表示与语言规律。相比传统的单向语言模型，BERT 引入了双向的 Transformer 编码器（Transformer encoder，其每一 Token 会 Attend 到所有的 Token），经过多层双向 Transformer 结构的堆叠后，形成 BERT 的主体结构。这样的做法使得模型能够同时考虑词语的上下文信息。BERT 接受的输入是每个 Token 的表征，这个表征由三个部分构成：Token 本身、分隔符（用于区分句子）和位置嵌入。[38]BERT 的预训练和微调模型任务如图 6 所示。

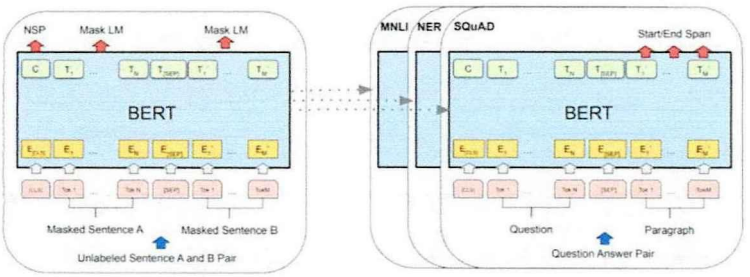


图 6（a）BERT 预训练任务[38] （b）BERT 微调任务[38]

BERT的预训练过程包括以下两个核心任务：掩码语言建模（Masked Language Model，MLM）和下一句预测（Next Sentence Prediction，NSP）。[38] 在 MLM 任务中，输入文本序列中的部分词汇被随机遮蔽，模型需要基于双向上下文信息预测被遮蔽的词汇。[38]MLM 任务更倾向于抽取 token 级别的表征，因此无法直接获取句子级别的表征。为了让模型能够有能力来理解句子间的关系，在 NSP 任务中，模型通常需要判断两个句子是否具有连续性关系。预训练完成后，BERT 模型能够迁移到多种下游自然语言处理任务中，包括文本分类、命名实体识别（NER）以及问答系统（QA）等[38]通常，将预训练的 BERT 模型与任务特定的输出层结合起来，通过微调（Fine-tuning）的方式对整个模型进行训练。[38]

BERT 的优势在于能够捕捉词语和上下文之间的关系，从而提供更好的语义表示。它能够理解句子的含义、处理指代消解、理解词语的多义性等复杂的语言现象。同时，BERT 的预训练和微调机制使其具有较强的迁移学习能力，即在一个领域上进行预训练后，可以在其他领域上进行微调，并达到较好的效果。[81]

中国知网 https://www.cnki.net

然而，BERT 模型也存在一些挑战。[82]首先，它需要大量的计算资源和时间进行预训练。其次，模型的规模较大，同时需要大规模的数据进行训练和微调。此外，BERT 对于输入序列的长度有一定的限制，过长的序列可能会导致性能下降。

总的来说，BERT 模型在自然语言处理任务中通过预训练和微调取得了显著的成就。它在语义理解、文本生成和各种下游任务中都具备优秀的性能，并且在学术界和工业界得到广泛应用。

2.2.7 ERNIE

ERNIE（Enhanced Representation through kNowledge IntEgration）是一个由百度开发的基于 Transformer 模型的预训练语言模型。[41]它在 BERT 的基础上进行了改进，引入了知识融合机制，通过将知识和文本相结合来增强表示能力。[41]

ERNIE 提供了三种不同的预训练框架：ERNIE 1.0 、ERNIE 2.0[83]和 ERNIE 3.0[84]。ERNIE 1.0 在预训练阶段主要使用了类 BERT 的掩码语言模型（Masked Language Model，MLM）和下一句预测（Next Sentence Prediction，NSP）任务，也就是说 ERNIE 1.0 使用的是 BERT 作为 backbone。[41]但与 BERT 不同的是，ERNIE 1.0 引入了实体和短语级别的掩码，通过关注实体信息来提升模型对实体级别语义的理解，同时它新增了 DLM（Dialogue Language Model）任务和采用更多的训练数据。ERNIE 2.0 则进一步引入了知识融合机制。它使用了三个新的预训练任务：词法关系预测（Lexical Relation Prediction）、句法关系预测（Sentence Order Prediction）以及语义预测。通过这三个任务，ERNIE 2.0 可以更好地理解词语和句子之间的关系，从而提升表示能力。[83]

ERNIE 3.0 融合了自回归和自编码网络，其模型在文本生成和语言理解任务中展现出卓越的性能，同时在预训练阶段引入了知识图谱数据。[84]ERNIE 3.0 的模型架构如图 7 所示。

ERNIE 3.0 创新性地提出了一种持续多范式统一的预训练框架。[84]在深度学习网络中，底层网络结构用于提取通用的低阶特征，越高层的网络用于提取越高阶特征。不同的自然语言处理任务范式共用底层抽象特征，如词汇信息和句法信息，但对顶层具体特征的要求是不相容的，例如 NLU 任务更倾向于语义连贯，而 NLG 任务更希望获得更多的全局信息。在预训练过程中，ERNIE 3.0 继续采用 ERNIE 2.0 的多任务持续预训练架构。[84]ERNIE 3.0 的整体架构包含两个部分：

Universal representation：采用多层 Transformer-XL 架构作为通用语义特征抽取器，其参数在自然语言理解（NLU）与自然语言生成（NLG）等任务范式间共享。[84]

Task-specific Representation Module：Task-specific Representation Module 也基于多层 Transformer-X 结构构建，其中 NLU 任务采用双向编码器层，而 NLG 任务则使用单向

中国知网 https://www.cnki.net

自回归模型。[84]

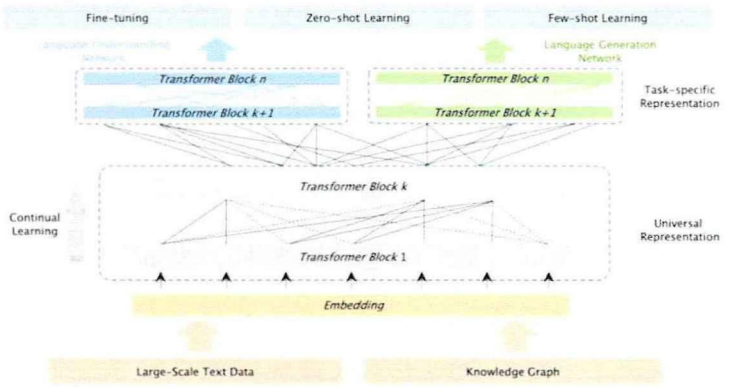


图 7 ERNIE 3.0 的模型架构[84]

ERNIE 通过预训练和微调的方式在各种下游任务中取得了优秀的性能，在文本分类、问答系统、命名实体识别等领域都取得了突出的结果。它在理解语义、处理实体信息以及句法关系上具备一定的优势，并且对于迁移学习也有较好的效果。总的来说，ERNIE 是一个在 BERT 基础上改进的预训练语言模型，通过引入知识融合机制和不同的预训练任务，增强了模型对语义、实体和句法关系的理解能力。它在自然语言处理领域有着广泛的应用，并且在学术界和工业界获得了良好的评价。[85]

2.2.8 DeepSeek

DeepSeek 是由杭州深度求索人工智能基础技术研究有限公司[86]开发的开源大语言模型。2024 年 12 月 26 日，DeepSeek 新系列模型 DeepSeek-V3 首个版本上线并同步开源。[86]这是一个强大的专家混合（MoE）[87]语言模型，总共有 671B 个参数，每个 token 激活了 37B。为了实现高效的推理和具有成本效益的训练，DeepSeek-V3 采用了多头潜在注意力（MLA）和 DeepSeekMoE 架构，这些架构在 DeepSeek-V2 中得到了全面验证。[88] 此外，DeepSeek-V3 开创了一种用于负载均衡的辅助无损策略，并设定了多标记预测训练目标以获得更强的性能。官方在 14.8 万亿个多样化和高质量的 token 上对 DeepSeek-V3 进行预训练，然后是监督微调和强化学习阶段，以充分利用其功能。综合评估表明，DeepSeek-V3 的性能优于其他开源模型，并实现了与领先的闭源模型相当的性能。[86]

中国知网 https://www.cnki.net

3 中国专利数据的分析研究

3.1 专利数据介绍

根据中国专利法规定，专利是指针对产品、方法或其改进所提出的新的技术方案。[89]要获得专利权的授予，发明创造需要满足三个特性：新颖性、创造性以及实用型。申请专利用的文件称之为专利申请文件，专利申请文件对于专利申请是非常重要的，申请文件的构成也是非常复杂，一份完整的申请文件包含很多复杂的内容，其大致包含的信息如图 8 所示。发起专利申请的主体按照专利法和专利审查指南，概括起来大致有如下 5 类，如图 9 所示。

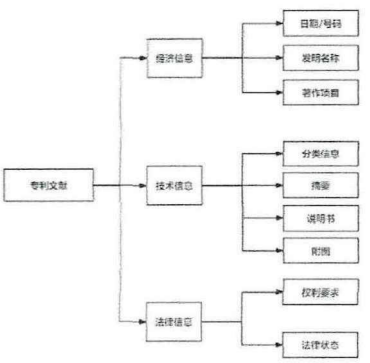


图 8 专利文献的基本构成

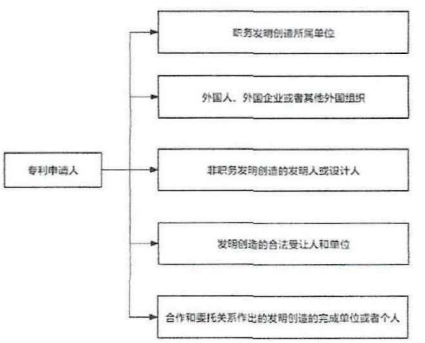


图 9 专利申请主体

专利的三大主要特性包括专有性、地域性和时间性。其中值得注意的是，专利的地域性是指在某一国申请的专利只在某一国得到保护。这里就涉及到涉外专利申请的问题，申请人可以就同一个发明创造依靠传统的巴黎公约体系和 PCT 体系这两种途径在不同国家申请专利，PCT 体系是目前比较常用的进入国外申请的途径。专利的时间性是指专利被授予权利后，得到专利保护的时间期限。[90]

中国专利按照国家知识产权局（CNIPA）的规定，目前主要有三分类，分别是发明专利（Invention Patent）、实用新型专利（Utility Model Patent）和外观设计专利（Design Patent）。发明专利是指涉及新的技术方案、产品或方法。发明专利是最常见和最高级别的专利类型。实用新型专利是指涉及对现有产品或方法的改进。实用新型专利在技术上相对较简单，创新水平较发明专利低。外观设计专利是指新设计涉及产品外观的一种专利，包括形状、图案和颜色等。外观设计专利保护产品的外观美学特征。[91-93]

中国知网 https://www.cnki.net

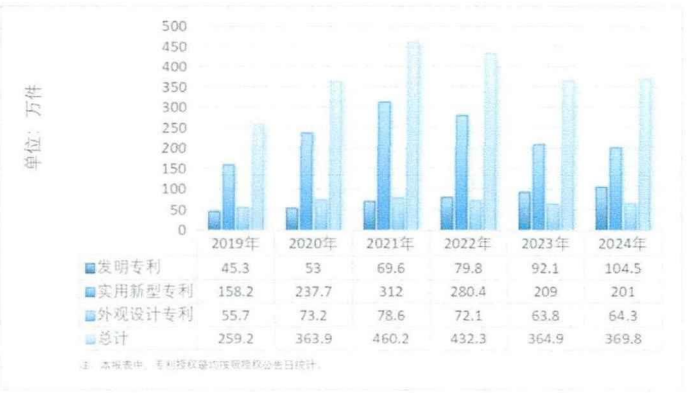
3.2 专利文本数据的相关可视化分析

3.2.1 专利数量类评价

（1）专利申请量与申请趋势分析

专利申请量可以反映专利申请的重要性和关注程度，而专利申请的趋势在某种程度上反映了社会科技创新的活跃水平。

根据《国家知识产权局年报》[94]中的附录统计数据，本文对从 2019 年到 2024 年申请的中国所有专利按照发明专利、实用新型专利和外观设计专利三种类型进行申请量和申请趋势上的分析。根据图表 10 进行分析，可以看出专利申请总体上呈现增长趋势，专利申请意识逐渐增强，社会对专利和科技创新的关注度也在不断提高。



	2019年	2020年	2021年	2022年	2023年	2024年
发明专利	45.3	53	69.6	79.8	92.1	104.5
实用新型专利	158.2	237.7	312	280.4	209	201
外观设计专利	55.7	73.2	78.6	72.1	63.8	64.3
总计	259.2	363.9	460.2	432.3	364.9	369.8

图 10 专利申请数量及趋势

（2）专利类型分析

发明专利、实用新型专利和外观设计专利是三类不同类型的专利，它们各自反映了不同的科学技术水平。其中，发明专利被认为是技术水平最高的，而外观设计专利的技术水平相对较低。通过研究专利的类型分布，可以更好地了解不同技术领域的创新活动和发展趋势。[95]

专利类型分布可以揭示当前的技术热点和研发方向。[96]某些专利类型可能在特定领域或行业中占据较大比例，表明该领域正在经历快速的技术发展和创新。不同的技术领域可能有其独特的需求和创新模式，从而导致专利类型分布的差异。比如，在某些领域，发明专利数量较多，说明该领域能够产生具有实质性技术突破的发明；而在某些领域，实用新型专利或外观设计专利的数量相对较多，可能意味着该领域更注重技术改进和外

中国知网 https://www.cnki.net

观设计的创新。不同行业中专利类型的分布也可以反映行业的竞争态势和创新重点。例如，在高科技领域，发明专利的比例可能较高，说明企业在技术研发和核心创新方面具有竞争力；而在消费品行业，外观设计专利的比例可能较高，表明企业更注重产品外观设计和品牌差异化。企业或组织的创新战略可能会影响专利类型分布。某些企业可能更注重发明专利，以保护核心技术和知识产权；而另一些企业可能更关注实用新型专利，以快速推出改进性产品并占领市场份额。

需要注意的是，专利类型分布只是创新活动的一个指标，还需要结合其他因素进行综合分析。

根据国家知识产权局的数据[94]，如图 11 所示。截止 2024 年 12 月，国内有效的发明、实用新型和外观设计专利分别为 4756307、11606374 和 2949290 条；国外有效的发明、实用新型和外观设计专利分别为 932560、50737 和 124622 条。通过分析专利类型的数量和比例，可以发现实用新型专利和发明专利是专利中数量最多的类型。其中，实用新型专利的数量和比例占据最高比例，而发明专利位居其次，外观设计则处于较低水平。这说明目前专利创新已经完成了从最初创新到吸收消化再到创新能力的演变，但市场创新的能力尚需进一步提升。

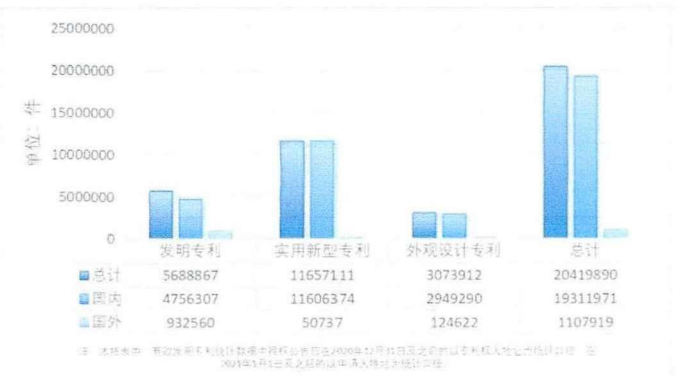


图 11 国内和国外有效专利分布状况

3.2.2 专利价值类评价

（1）专利权人分析

对相关专利权人的分析可以提供有关创新者和企业的相关信息，对于评估技术创新活动、市场竞争格局以及企业战略布局等方面具有重要意义。

通过专利权人分析，可以了解到参与特定领域或行业的创新者的身份。这些专利权人可能是大型企业、中小型企业、研究机构、高校或个人发明家等。创新者的身份可以

中国知网 https://www.cnki.net

提供关于行业内主要参与者的信息，帮助了解行业竞争状况和技术创新力量的分布。[97]

同时，专利权人分析可以揭示不同企业或机构的创新活跃度。某些企业或机构专利申请的数量较多，表明其在技术研发和创新方面非常积极，并具有较强的创新实力。这些创新者可能在市场上具有竞争优势，也可能是该领域的技术领导者。[98]

并且，专利权人分析还可以揭示企业或机构的技术布局和创新战略。通过分析专利权人的专利组合，可以了解到他们在不同技术领域的创新重点和专长。这有助于评估企业或机构的技术战略，确定其关注的核心技术领域以及未来可能的发展方向。[99]

最后，通过专利权人分析，可以发现不同创新者之间的合作与竞争关系。某些企业可能频繁合作，共同开展研发项目或实施技术转让；而其他企业可能存在竞争关系，彼此角逐市场份额和技术优势。这些信息有助于了解行业内的合作网络和竞争格局。[99]

需要注意的是，通过专利权人分析只能提供一定的信息参考，还需综合其他因素进行深入的市场、技术和竞争分析，才能得出更全面的结论。

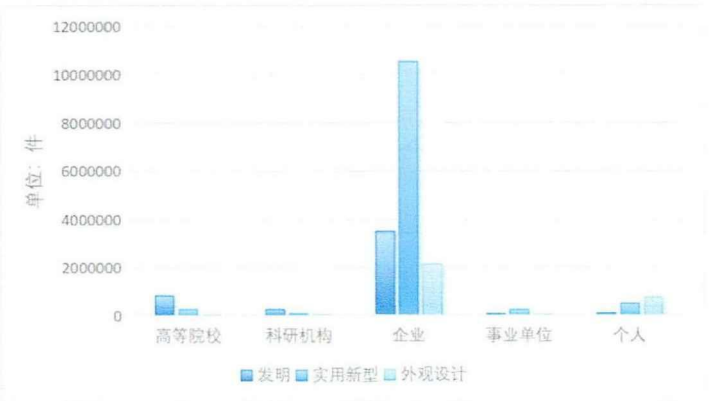


图 12 有效专利按专利权人的分布状况

根据国家知识产权局数据[94]，对截止到 2024 年 12 月的有效专利数据按照专利权人进行统计分析，数据结果如图 12 所示。参与统计分析的专利权人共有五类，分别是高等院校、科研机构、企业、事业单位和个人。如图 12 显示，五种专利权人中，企业在三种专利类型中的占比都是最高的；个人在实用新型和外观设计这两种专利上申请的数量较多；相比个人，高等院校在发明和实用新型专利上贡献的专利数量较多；事业单位在实用新型上专利数量较多。科研机构具有和企业相似的专利贡献特征；高等院校和科研机构相似的专利申请状况表明了高校人才是主要的科研力量，高校和机构紧密联合、互相合作；目前，在我国专利申请总量中，企业占据很大一部分份额，它是技术研发和创新方面的中坚力量，具有很强的创新能力。

中国知网 https://www.cnki.net

（2）专利地域分析

专利地域分析是研究不同地区或国家在专利创新方面的表现和趋势的一种方法。

通过分析专利申请的地域来源，可以了解到哪些地区是创新活动的热点。这些地区可能拥有丰富的科研机构、创新型企业和优质人才，对于技术创新和发展具有重要意义。[100]

不同地区在不同技术领域可能存在着自身的优势。通过专利地域分析，可以了解到某个地区在特定领域的专利数量和技术分布情况。这有助于了解地区的核心竞争力和技术特长，为制定政策和战略提供参考。[101]

专利地域分析还可以揭示出一个地区的创新生态系统，包括大型企业、中小企业、高校、科研机构等各类创新参与者的分布和互动关系。这有助于评估地区的创新能力和科技创新生态的健康度。[95, 102]

需要注意的是，专利地域分析只能提供定性的信息参考，并不能完全代表一个地区的创新实力。综合其他因素进行深入的市场、技术和竞争分析是更全面评估地区创新活动的重要手段。

现对 2024 年度的专利数据[103]按照地域进行统计分析，数据结果如图 13-15 所示。重点区域如京津冀、长三角、粤港澳、成渝地区的企业在发明专利获取方式、研发经费支出和产业化率三个方面上数据各有明显差异。

分重点区域看，京津冀地区、长三角地区、粤港澳大湾区以及成渝地区企业发明专利通过研发获取的比例、研发支出的比例以及产业化率均高于其他地区。。2024 年专利调查首次对区域调查主要数据进行了分析，这次调查反映各区域在专利创造、转化运用、保护等方面具有差异化特征。[103]

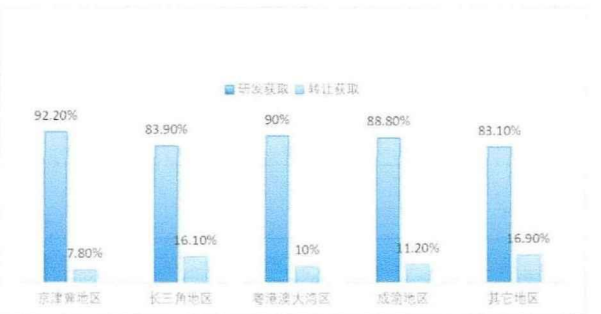


图 13　重点区域企业发明专利获取方式（2024）

中国知网　https://www.cnki.net

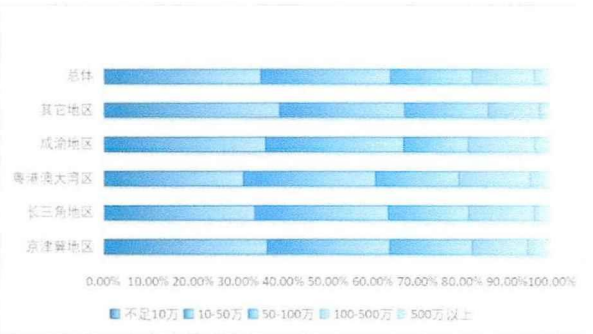


图 14 重点区域企业发明专利研发经费支出比例（2024）

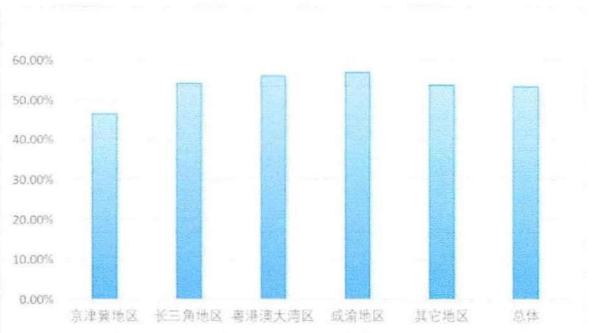


图 15 重点区域企业发明专利产业化率（2024）

3.2.2 专利质量类评价

（1）IPC 分类分析

国际专利分类法（IPC，International Patent Classification）作为一种标准化的专利等级体系，通过语言无关的符号系统将技术领域系统性地划分为部门、类和组三个层次。每个部门和类都代表不同的技术领域，用于按所属不同技术领域对专利进行分类。[13]

在 IPC 分类表中，特定时间段内专利申请量激增且技术发展迅速的技术领域通常被定义为活跃技术领域。在活跃技术领域中，实力雄厚的科研团队往往形成创新集群，通过采取进攻性专利战略（Offensive Patent Strategy）来巩固其技术领先地位。这些团队不仅利用专利权构建技术壁垒，还通过专利布局最大化市场份额，从而在激烈的技术竞争中占据主导地位。IPC 的分类体系由数字和字母的组合构成的代码组成：一个完整的分类号包括代表部、大类、小类以及大组或小组的类号[13]，其中部用字母 A 到 H 表示不

中国知网 https://www.cnki.net

同的技术领域。这些字母的含义由图 16 所示。

根据国家知识产权局数据，对从 2017 年到 2023 年的发明和实用新型专利数据按照 IPC 分类中的部进行统计分析，具体统计结果如下表 1 所示。

由图表可知：从 2017 年到 2023 年，在 A 至 H 这八个部门中，B 部以 32.73%的比例位居科技创新活跃度的首位；随后依次是 G 部、A 部、H 部与 F 部，它们的占比分别为 14.64%、13.61%、12.95%以及 11.25%。

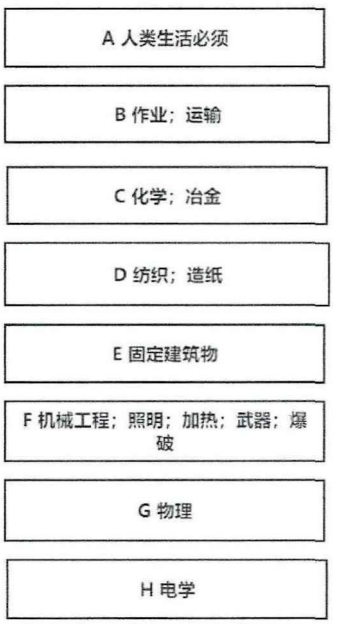


图 16　IPC 分类中部的对应类名

由此观察，可以明显看出，A 部、H 部、G 部和 F 部四个部门是专利创新活动的主要集中地；从专利所在产业分析，固定建筑物、化学和冶金、纺织和造纸都是相对来说较为弱势的领域；在发明专利中，物理类占据最大比例，达到 26.3%，纺织和造纸仅占 1.4%；在实用新型专利中占据最大比例的是作业和运输，最小比例的同样是纺织和造纸类。从专利大类排名可以看出专利的发明创造活跃领域与国家政策重点领域呈现一致，诸如作业运输和物理学所代表的某些高新技术产业，以及国家重点支持的电子信息科学技术、新能源和节能等技术领域都呈现蓬勃发展的态势。

（2）洛伽诺分类

国际外观设计分类（洛迦诺分类）[104]是针对于外观设计专利而设计的分类方案。第 13 版洛迦诺分类（《国际外观设计分类表》）在 2020 年 6 月正式公布，在次年 1 月 1

中国知网　https://www.cnki.net

日正式实施。[104]

洛迦诺分类共有 32 大类以及对应每一大类下的数个小类。外观设计分类的目标在于确认外观设计产品的属性类别，便于外观设计专利的分类管理，以及方便进行外观设计专利的快速检索查询，同时按照分类号次序编排和公告外观设计专利文本。[104]

表 1 发明和实用新型专利按 IPC 部的分类

发明和实用新型专利授权按IPC部的分类统计表（2017-2023）

Patent Grants for Invention and Utility Model by Sections of IPC (2017-2023)

单位：件 (Unit: piece)

分类 Classification	发明 Invention		实用新型 Utility Model	
	数量 Number	构成 %	数量 Number	构成 %
A----H 合　　计 Total	4250312	100.0%	14426329	100.0%
A部　Section A 人类生活必需 Human necessities	377833	8.9%	2163631	15.0%
B部　Section B 作业、运输 Performing operations; Transporting	776357	18.3%	5335898	37.0%
C部　Section C 化学、冶金 Chemistry;Metallurgy	592676	13.9%	501008	3.5%
D部　Section D 纺织、造纸 Textiles;Paper	61310	1.4%	210007	1.5%
E部　Section E 固定建筑物 Fixed constructions	168522	4.0%	1234342	8.6%
F部　Section F 机械工程；照明；加热；武器；爆破 Mechanical Engineering; Lighting; Heating; Weapons; Blasting	281828	6.6%	1820179	12.6%
G部　Section G 物　　理 Physics	1119913	26.3%	1614423	11.2%
H部　Section H 电　　学 Electricity	871873	20.5%	1546841	10.7%

中国知网 https://www.cnki.net

4 文本自动分类模型的设计与实验

BERT 和 ERNIE 都是基于 Transformer 的目前比较流行的预训练语言模型，本节根据模型融合原理设计了基于 BERT 和 ERNIE 的八个文本自动分类模型，最后将各模型在 THUCNews 数据集上进行训练并对模型文本分类的具体结果进行了比较。

4.1 文本自动分类模型的设计

在上文中介绍了 BERT 和 ERNIE 两种模型的基本架构，它们都是基于 Transformer 改进而来的，所以 BERT 和 ERNIE 这两个模型的输入和输出在一定程度上很相似。

模型的输入向量由三种不同的 Embedding 求和生成，这三种 Embedding 包括 Token Embedding、Position Embedding 和 Segment Embedding。Token Embedding 是指对单词进行向量化表示。在该方法中，Token Embedding 通过将单词分解为有限通用子词单元（Subword Units），实现了单词完整性与字符灵活性之间的优化平衡。Position Embedding 通过将单词的位置信息编码为特征向量，弥补了非递归神经网络架构在序列位置信息获取方面的不足。最后，Segment Embedding 作为区分两个句子的向量表示，在非对称文本场景（如问答系统）中发挥着关键作用。这种多维嵌入机制不仅增强了模型的语义表示能力，还为处理复杂文本结构提供了有效解决方案。

在模型的输出结果中，值得讨论的主要有四部分，分别是 Last_hidden_state、Pooler_output、Hidden_states 和 Attentions。

Last_hidden_state：作为最后一层的隐藏状态输出，其数据格式为（batch_size, sequence_length, hidden_size），其中 hidden_size 固定为 768。

Pooler_output：采用（batch_size, hidden_size）的数据格式，通过对序列第一个 Token 的最后一层隐藏状态进行线性变换与 Tanh 激活处理生成，通常用于句子分类任务。用户可根据实际需求选择使用 Pooler_output 或整个输入序列的隐藏状态均值/池化结果。

Hidden_states：作为可选输出项，需通过 config.output_hidden_states 参数激活，其元组结构包含 Embedding 层及各层的输出，每个元素的格式为（batch_size, sequence_length, hidden_size）。

Attention：同样是可选输出项，需通过 config.output_attentions 参数激活，其元组元素表示各层的注意力权重，主要用于计算 self-attention heads 的加权平均值。这种多层次输出机制不仅为不同任务提供了灵活的特征表示选择，还通过注意力权重的可视化增强

中国知网 https://www.cnki.net

了模型的可解释性。

BERT 以及 ERNIE 的底层 Transformer 编码器（通常冻结前 N 层）作为通用语义表征基座，其输出的 Last_hidden_state 包含词汇、句法和基础语义信息。这种共享避免了从零训练深层语言模型的计算开销，同时保证了文本理解的普适性，本节中模型的融合主要使用模型输出结果中的 Last_hidden_state。

最终基于 BERT 和 ERNIE 设计了 BERT-TextCNN、BERT-TextRNN、BERT-TextRCNN、BERT-DPCNN、ERNIE-TextCNN、ERNIE-TextRNN、ERNIE-TextRCNN、ERNIE-DPCNN 共计 8 个文本分类模型。模型融合的总体架构如图 17 所示。

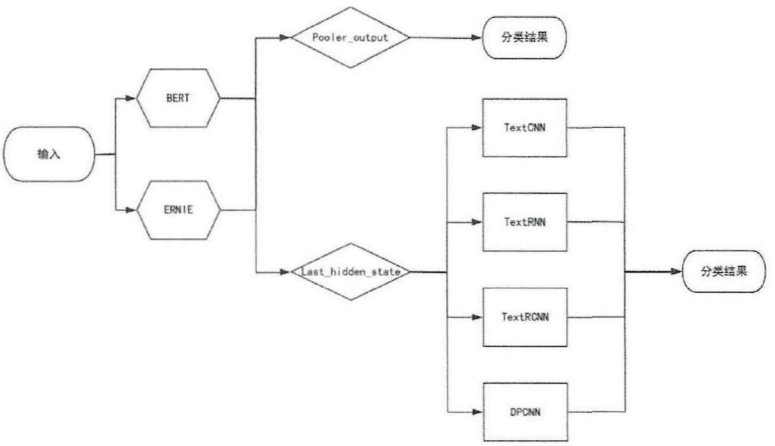


图 17 文本自动分类模型总体架构

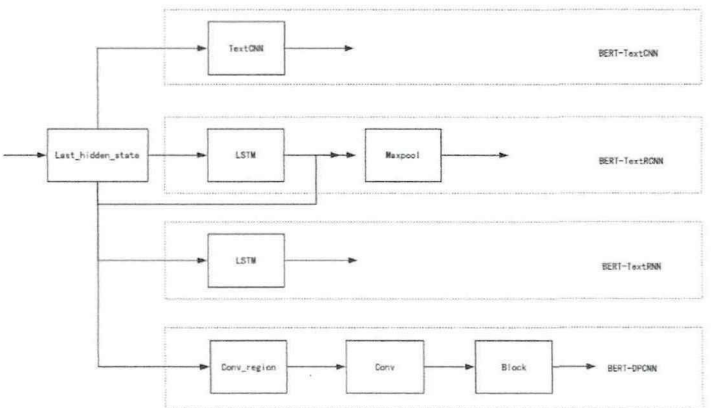


图 18 模型融合原理

中国知网 https://www.cnki.net

如图 18 所示，各模型通过差异化路径实现特征融合。

基于多尺度局部语义建模原理，将模型输出接入三种卷积核的 CNN，构成 BERT-TextCNN 模型；采用双向 LSTM 建模序列依赖关系，将模型输出接入 LSTM，构成 BERT-TextRNN 模型；将模型输出通过 LSTM 与其本身拼接，扩展为双层 LSTM 增强长程依赖捕捉，最后经过一层最大池化层，构成 BERT-TextRCNN 模型； 将模型输出经过一个包含三个不同卷积特征提取器的 Region 层，接着通过两层等长卷积来扩展感受野，以提供更广泛的特征提取，它主要通过深度金字塔卷积结构分层抽象语义，然后重复通过一个 1/2 池化的残差块（Block），1/2 池化的目的是持续增强词位的语义表达，其中 Feature_maps 这部分被固定，引入残差网络是为了解决在训练过程中可能出现的梯度消失和梯度爆炸问题，最终构成了 BERT-DPCNN 模型。

4.2 文本自动分类模型的实验

4.2.1 实验数据

为了客观评价上文中设计的模型的性能，本文从清华大学 THUCNews 开源数据集中提取了 20 万条新闻标题作为数据集进行新闻标题分类实验，数据集的划分如表 2 所示。数据集划分过程中通过分层抽样保持类别分布一致，确保评估结果可靠性，该比例参考了 THUCNews 原数据集及文本分类任务中的一般常规实践，在保证训练充分性的同时，兼顾验证与测试效率。[105]

本实验采用的多类别文本数据集共包含 10 个分类，每个类别包含 20,000 条新闻文本，文本长度分布在 20 至 30 个字符之间。数据集的类别涵盖股票、教育、科技、财经、房产、社会、时政、体育、游戏和娱乐等十个领域。在实验中，我们以字为单位输入模型，并采用了中文预训练词向量 Sogou News 搜狗新闻 Word+Character 300d。

表 2 数据集的划分

数据集	训练集	验证集	测试集
数据量	18 万	1 万	1 万

中国知网 https://www.cnki.net

表 3 实验环境

环境	说明
硬件平台	NVIDIA GeForce RTX 3080 Ti（24GB）
	CPU Intel(R) Xeon(R) Gold 6330
操作系统	Ubuntu18.04
编程语言	Python 3.8
深度学习框架	Pytorch 1.11.0

4.2.2 实验设计

（1）实验环境

本实验的环境如表 3 所示。实验中采用的操作系统是 Ubuntu18.04，GPU 是 NVIDIA GeForce RTX 3080 Ti，CPU 是 Intel(R) Xeon(R) Gold 6330，利用 Pytorch 1.11.0 深度学习框架和编程语言 Python 3.8 进行实验。本实验代码部分思路和调试借助 DeepSeek-V3 实现。

（2）评价指标

在文本分类中，通常使用精确率（Precision）、召回率（Recall）、准确率（Accuracy）、精确率和召回率的调和均值（F-Score，通常用 F1-score）等来对分类的好坏进行评价。以下是本实验中采用的文本分类评价指标以及其各自的定义公式。

以二分类问题为例，将关注的类别定义为正类，否则为负类，被正确分类的正类用 TP 表示，负类文本被预测为正类用 FP 表示；负类文本被预测为负类用 TN 表示，正类文本被预测为负类用 FN 表示。[106]

（1）准确率（Accuracy）：它的定义是指在分类结果为某一类别的数据中，真正属于该类别的数目所占的比例。在本实验中，取各类别结果的平均值。

$$A = \frac{TP + TN}{TP + TN + FP + FN} \tag{4-1}$$

（2）精确率（Precision）:计算在实际属于某一类别的数据中，分类正确属于该类别的数目所占的比例。在本实验中，取各类别结果的平均值。

中国知网 https://www.cnki.net

$$P = \frac{TP}{TP + FP} \tag{4-2}$$

（3）召回率（Recall）：该指标表示在所有实际为正样本的情况下，被正确预测为正样本的比例大小。

$$R = \frac{TP}{TP + FN} \tag{4-3}$$

（4）F1-score：精确度和召回率的调和均值，表明精确率和召回率同等重要。

$$F_1 = \frac{2TP}{2TP + FP + FN} = \frac{2P \times R}{P + R} \tag{4-4}$$

（3）参数设置

本实验中的参数具体设置如表 4 所示，其中由于实验数据文本长度不平衡，所以实验统一设置数据截取长度为 32。

表 4 实验参数设置

训练参数	详情
学习率	5e-5
训练轮数	3
每轮训练规模	128
数据截取长度	32
优化器	Adam

4.3 实验结果分析

依据本次实验结果，BERT 模型在中文文本分类数据集 THUCNews 上比 ERNIE 模型展现出更高的性能，如表 5 所示。

但是当将 ERNIE 模型和 BERT 模型分别与 TextCNN、TextRNN 和 DPCNN 这三个模型融合时，ERNIE 系列融合模型不仅在测试集上各指标均有所提升，而且与 BERT 系

中国知网 https://www.cnki.net

列融合模型相比均表现更优秀的中文文本分类性能，如表 6 所示。

对于与 BERT 融合之后的各个模型，当 BERT 与 TextRNN 和 DPCNN 模型融合时，各项评价指标均有所下降，融合后的模型在中文文本分类上表现较差，如表 6 所示。

在本次实验的所有中文文本分类模型中，ERNIE 与 DPCNN 相互融合的模型 ERNIE-DPCNN 在实验测试集上准确率达到了 94.82%，精确率达到了 94.85%，召回率达到了 94.82%,F1 值达到了 94.82%，比单纯的 ERNIE 模型准确率提高了 0.88%，表明采用 ERNIE-DPCNN 模型进行文本分类具有很强的可行性和有效性，这种融合模型特征提取能力最强，表现出非常好的分类性能。它在测试集上 10 个类别的具体评价指标结果如表 7 所示。

在实验数据报告中，统计显著性分析是提升结论严谨性的关键步骤，它可以避免因随机性导致的结论偏差，能够显著提升实验可信度。[107]本文基于测试集 10,000 条样本的准确率数据，通过两比例 Z 检验和 Bonferroni 校正[108]以及效应量（Cohen's h）[109]三个统计学指标对新构建的八个文本分类模型实验结果进行横向分析，指标数据结果如下表 8 所示。

由表 8 可以看出，ERNIE-DPCNN 显著优于 BERT-TextCNN、BERT-TextRNN、BERT-DPCNN、ERNIE-TextRNN、ERNIE-TextRCNN（Bonferroni 校正后仍显著），与 BERT-TextRCNN、ERNIE-TextCNN 的差异无统计学意义。所有显著差异的对比模型中，Cohen's h 均小于 0.08（小效应），提升幅度有限。最大差异来自 BERT-DPCNN（+0.70%），但实际应用价值需要结合业务需求来综合判断。

综上图表数据，各模型均展现较好的文本分类性能，证明了本次实验中所采用的模型融合方法的有效性和实用性。

表 5 BERT 和 ERNIE 在测试集上的各评价指标对比

模型	准确率(%)	精确率(%)	召回率(%)	F1-score
BERT	94.51	94.54	94.51	94.51
ERNIE	93.99	94.00	93.99	93.99

表 6 分别与 BERT 和 ERNIE 融合的各模型在测试集上的各评价指标对比

模型		准确率(%)	精确率(%)	召回率(%)	F1-score
BERT	TextCNN	94.66	94.69	94.66	94.66
	TextRNN	94.20	94.22	94.20	94.20
	DPCNN	94.12	94.17	94.12	94.11

中国知网 https://www.cnki.net

	TextRCNN	94.79	94.82	94.79	94.79
ERNIE	TextCNN	94.76	94.77	94.76	94.75
	TextRNN	94.63	94.69	94.63	94.64
	DPCNN	94.82	94.85	94.82	94.82
	TextRCNN	94.63	94.63	94.63	94.63

表 7 ERNIE-DPCNN 的各分类标签在测试集上的各评价指标对比

类别	准确率(%)	精确率(%)	召回率(%)
finance	92.96	95.10	94.02
realty	96.87	95.80	96.33
stocks	93.04	89.50	91.23
education	97.01	97.20	97.10
science	89.72	92.50	91.09
society	94.12	94.40	94.26
politics	92.39	93.50	92.94
sports	98.70	98.70	98.70
game	98.12	94.00	96.02
entertainment	95.59	97.50	96.53

表 8 实验结果统计学分析检验

对比模型	准确率(%)	p-value	Bonferroni 显著（α=0.00714）	Cohen's h	实际意义
ERNIE-DPCNN	94.82	—	—	—	—
BERT-TextRCNN	94.79	0.314	否	0.003	无实际差异
BERT-TextCNN	94.66	<0.001	是	0.016	微小提升
BERT-TextRNN	94.2	<0.001	是	0.062	小提升
BERT-DPCNN	94.12	<0.001	是	0.07	小提升
ERNIE-TextCNN	94.76	0.073	否	0.006	无实际差异
ERNIE-TextRNN	94.63	<0.001	是	0.019	微小提升
ERNIE-TextRCNN	94.63	<0.001	是	0.019	微小提升

中国知网 https://www.cnki.net

5 基于自然语言处理的专利文本自动分类系统

在上文中介绍了中国专利的现状，随着时代的蓬勃发展，专利数量呈现剧增的趋势，日益增多的各种专利表明了专利自动分类技术的迫切需要。实现高效的专利自动分类，不仅可以节省大量人力和财力，更可以使专利信息更加有序和更易获取，为人们的创新活动和知识应用提供强有力的支持和指导。[10]

本节基于前文内容主要实现了三种中国专利文本自动化分类的技术方案，并设计并部署了中国专利文本智能分类系统，其中系统亦增设了专利关键词自动提取模块。

5.1 专利文本分类方案的实验

5.1.1 基于 BERT 和 ERNIE 的文本分类模型实验

（1）实验流程

该实验中的具体流程共分为 5 个步骤，如图 19 所示，分别是：专利文本数据集构建，文本预处理，模型训练及调参、模型分类效果评估和模型推理预测。图 19 具体内容解释如下：

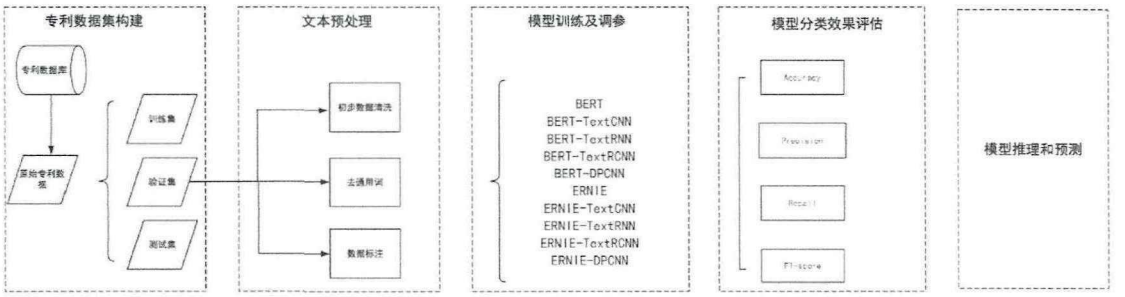


图 19 实验流程图

（a）专利文本数据集的构建。从国家公布的专利数据中提取出一定数量的并且带有类别标签的专利文本数据，作为原始数据集集合。在实验设计阶段，数据集被系统性地划分为训练集、验证集和测试集三个部分。其中，训练集用于模型参数的优化与学习，验证集则通过监控模型在未见数据上的表现来防止过拟合（Overfitting）现象，而测试集

中国知网 https://www.cnki.net

则作为最终评估模型泛化能力（Generalization Ability）的基准。这种科学的数据划分方法不仅确保了模型训练的有效性，还为模型性能的客观评估提供了可靠依据。

（b）文本预处理。在利用第一步提取的专利数据时，由于可能存在大量噪音信息，因此需要先进行预处理以改善数据质量，以便后续模型能够更好地利用。

首先进行初步的数据清洗。去除特殊字符：可以通过使用正则表达式来批量清理文本中的非文字字符，比如特殊符号和一些表情符号，以及非目标语言的文字，例如法语和西班牙语。去重：提取的专利数据中会存在具有较大相似度或者重复的数据，不利于模型的训练，所有采用去重算法进行数据处理。去异常文本：在获取数据时，往往会因为多方面因素得到一些异常数据，简单的数据清洗通常难以判别，但在程序运行过程中，会提示错误信息，这时候就需要回到原始数据集进行重新处理。

然后对数据进行通用词去除操作，结合使用百度停用词表和哈尔滨工业大学停用词表，去除普通停用词以减少数据中的干扰内容。

最后对数据进行规范性标注。针对分类的内容，对每一条分类数据进行规范标注。

（c）模型训练及调参。本节实验采用 BERT 和 ERNIE 基础文本分类模型和前文所设计的它们分别与 TextCNN、TextRNN、TextRCNN 和 DPCNN 融合的文本自动分类模型进行训练和参数调优。

（d）模型分类效果评估。根据实验数据和各自分类的内容在文本分类模型的测试集上进行测试，根据上文中的精确率、准确率、召回率和 F1 值这四个实验评价指标对所建立的模型进行评价，比较各自的分类结果，做出分析。

（e）模型推理和预测。任意输入专利的一条或几条文本数据，按照不同分类体系和分类模型，输出专利分类对应的结果。

（2）实验环境和参数设置

本实验的环境如下表 9 所示。实验中采用的操作系统是 Ubuntu18.04，GPU 是 NVIDIA GeForce RTX 3090，CPU 是 Intel(R) Xeon(R) Gold 6330，利用 Pytorch 1.9.0 深度学习框架和编程语言 Python 3.8 进行实验。本实验代码部分思路和调试借助 DeepSeek-V3 实现。

中国知网 https://www.cnki.net

表 9 实验环境

环境	说明
硬件平台	NVIDIA GeForce RTX 3090（24GB）
	CPU Intel(R) Xeon(R) Gold 6330
操作系统	Ubuntu18.04
编程语言	Python 3.8
深度学习框架	Pytorch 1.9.0

本实验中的参数具体设置如表 10 所示，其中，由于实验数据文本长短不平衡，所以统一设置数据截取长度为 128。

表 10 实验参数

训练参数	详情
学习率	5e-5
训练轮数	12
每轮训练规模	128
数据截取长度	128
优化器	Adam

（3）实验数据和实验内容

本节从 1985 年到 2024 年我国所公布的专利数据中，随机采集 15000 条专利文本数据构成原始数据集，其中发明专利、实用新型专利和外观设计专利数据各占 5000 条。本次实验目的是按照两种分类体系对中国的专利文本数据实现自动分类，共进行了两个实验：

实验一：对专利数据按照专利类型实现自动分为发明专利、实用新型专利和外观设计专利三类；

中国知网 https://www.cnki.net

表 11 经过初步数据清洗后实验二的数据

分类类别	实用新型专利	发明专利
A	1064	652
B	1321	694
C	136	1045
D	120	125
E	536	101
F	706	332
G	243	776
H	371	724
总计	4497	4449

实验二：对实用新型专利和发明专利按照 IPC 分类体系自动分成八大类;

其中实验二所用的实验数据经过初步数据清洗后如表 11 所示。可以看到，数据类别出现明显不均衡现象，在不均衡数据上训练的分类算法往往导致预测的质量较差等问题。为了避免数据不均衡造成实验精度的影响，本实验中采用随机过采样的方法，通过增加分类中少数类样本的数量来减少样本不均衡对实验结果造成的误差。

在本节中，将数据集按照 8：1：1 的比例划分为训练集、验证集和测试集，以进行两个文本分类实验。在模型开发流程中，训练集被专门用于模型的学习与参数优化，通过最小化损失函数来实现模型性能的提升。验证集则通过监控模型在未见数据上的表现来调节超参数，从而有效防止过拟合（Overfitting）现象的发生。测试集作为最终评估模型泛化能力（Generalization Ability）的基准，其评估结果反映了模型在真实场景中的实际表现。

（4）实验结果

在前文实验中，ERNIE-DPCNN 模型在清华大学开源数据集 THUCNews 进行文本分类的可行性和有效性特征提取的能力最强。在本实验数据集上，对专利按照类型分类，ERNIE-DPCNN 模型在测试集上的准确率达到 98.63%，损失是 0.038；对专利按照 IPC 进行分类，ERNIE-DPCNN 模型在测试集上的准确率达到 76.81%，损失是 0.72；其余各模型在两种分类体系上亦具有较好的分类表现。

5.1.2 基于 DeepSeek-V3 的文本分类模型实验

中国知网 https://www.cnki.net

本实验采用零样本学习（Zero-Shot）和指令调优（Instruction Tuning）相结合的方法对 DeepSeek-V3 应用提示词工程，实现中国专利文本数据的自动化分类，实验架构设计如下表 12 所示。

表 12 基于 DeepSeek-V3 实现文本分类的架构设计

模块层级	组件名称
输入层	请求队列
预处理层	批处理模块
通信层	API 并发控制器
服务层	DeepSeek-V3 API
后处理层	结果解析器

5.1.3 基于 LangChain 的文本分类模型实验

本实验采用框架级方案 LangChain 集成管理大语言模型 DeepSeek-V3，通过任务流程模块化编排实现了文本自动化分类,实现处理流程图如下表 13 所示。

表 13 基于 LangChain 的文本分类处理流程设计

处理阶段	组件名称
模板生成	PromptTemplate
模型推理	LLM(DeepSeek-V3)
结果标准化	OutputParser

5.1.4 专利文本关键词提取的实验

专利关键词提取是专利文本分析领域一个很重要的部分，通过对文本提取的关键词可以迅速掌握整个专利的主题思想，进一步应用于专利的高效分类。

关键词提取主要分为有监督和无监督两种范畴[110]，本实验采用无监督算法中的 TF-IDF 关键词提取方法。实验代码中使用了 jieba 分词中的 tfidf 函数实现了对专利文本任意数量关键词的自动提取功能。

中国知网 https://www.cnki.net

5.2 专利文本自动分类系统的设计

人工智能飞速发展的今天，简单明了的可视化展示使得具有良好性能的模型更容易发挥它本身的价值。越来越多的性能非常好的模型开始部署落地，应用在有需要的地方。在实际运用中，常见做法是将模型部署在服务器上，数据获取后传送至指定的服务器，模型可对接收到的数据进行在线处理。本文同样采用这种部署的方法。

Gradio 是一个 Python 库，可用于创建交互式界面，适用于深度学习模型。本文基于 Gradio 完成对专利文本自动分类系统的前端界面搭建工作。

本节设计的专利文本自动分类系统整体结构分为两部分，分别是后端的专利文本自动分类模型部分和前端的可视化分类界面部分，系统总体框架如图 20 所示。当将一条专利的文本数据输入到前端界面时，文本分类模型将对其进行自动分类，完成分类后通过后端处理程序将分类结果展示到构建的前端界面中。

最终，终端用户可以实现对任意一条专利文本按照不同分类体系，任意选择基于不同技术路线的分类模型进行分类，其中系统也增设了对专利文本任意数量的关键词自动提取的功能板块。

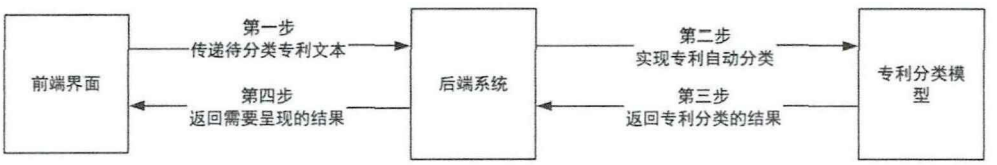


图 20 专利文本自动分类系统总体架构

5.3 专利文本自动分类系统的测试

5.3.1 专利文本自动分类系统的前端网页界面

打开服务器后通过 SSH 实现远程连接。首先输入 SSH 指令、密码以及代理端口开始代理。然后通过 http://localhost:7860/这一地址进入系统主页。

中国知网 https://www.cnki.net



图 21 专利文本自动分类系统界面

图 21 为专利文本自动分类系统的前端界面，系统界面分为左右两区域。

左侧有两个输入框：专利文本输入框和关键词提取的数量（默认为 3 个）输入框；两个选择框：专利分类体系和基于三类技术路线的十二种专利文本分类模型；

右侧有两个输出框：分类结果输出框和专利关键词输出框；

5.3.2 专利文本自动分类系统的测试

用户可以根据实际情况选择填写或选择需要分类的专利文本、分类的体系、分类模型以及需要提取的关键词数量。填写的数据会发送给后端指定的服务器，在后端完成文本数据的接收和处理操作，并调用由 Python 编写好的代码完成结果的输出。下面以图 22-图 25 展示专利文本自动分类系统的具体功能。

中国知网 https://www.cnki.net



图 22



图 23

中国知网 https://www.cnki.net

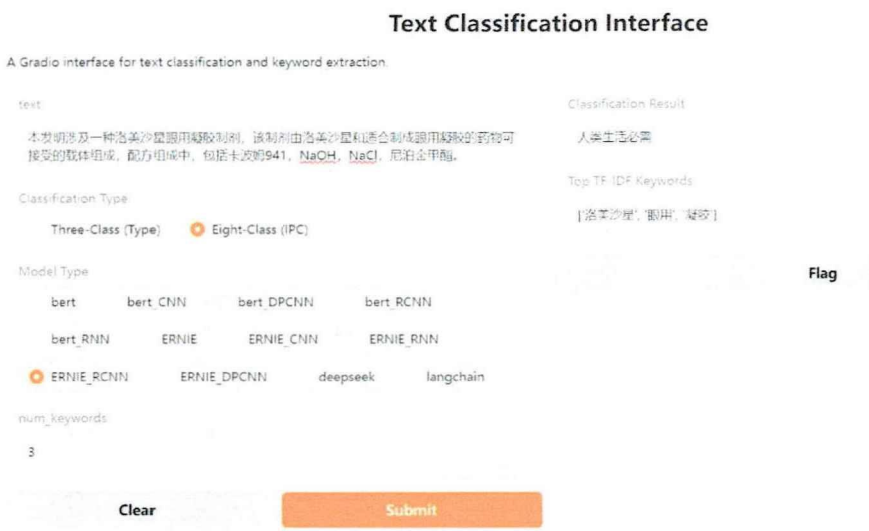


图 24



图 25

中国知网 https://www.cnki.net

6 总结与展望

6.1 工作总结

专利文本数据在各自分类体系中的自动化分类具有很多极其重要的意义。它可以帮助我们了解不同技术领域的发展趋势，这有助于企业、研究所和政府等机构预测未来的技术发展方向，以便做出战略决策和规划。总之，对于专利的分析和分类可以提供有关技术趋势、竞争情报、产品研发、专利价值评估和技术合作等方面的重要信息，帮助企业和研究机构做出明智的决策和规划。

本文对我国专利文本数据所做的分析研究和分类工作主要如下：

第一，对国家知识产权局最近几年所公布的专利数据进行一些可视化分析。从数量类、质量类和价值类三个维度对专利展开数据分析。在数量类中，分析专利申请量和申请趋势以及专利类型的占比情况；在价值类中，分析专利权人和专利主要申请地域的一些具体情况；在质量类中，介绍不同专利类型的两大分类体系，包括 IPC 分类和洛迦诺分类，其中对 IPC 分类进行了详细的数据统计分析。

第二，基于模型融合原理，设计并构建了八种文本自动分类模型。目前比较流行的语言预训练模型有基于 Transformer 的 BERT 和 ERNIE 等，TextCNN、TextRNN、TextRCNN 和 DPCNN 等模型在文本分类等自然语言处理工作上也表现出优良的性能。于是本文的想法是将 BERT 和 ERNIE 分别 TextCNN、TextRNN、TextRCNN 和 DPCNN 这四个模型进行融合，设计并构建八种融合后的新模型用于实现文本的自动分类，并在开源数据集 THUCNews 进行文本分类的可行性实验，通过各种评价指标，最终证明了本文所构建的融合模型的有效性和实用性。

第三，基于三种文本分类技术路线设计并部署了中国专利文本自动分类系统，并且增设了专利关键词提取模块。

本文从 1985 年到 2024 年的中国专利数据库中随机采集 15000 条专利文本数据作为实验数据来源，根据专利的两种分类体系，建立对应的专利分类数据集，在这两个数据集上进行文本分类实验。实验进一步证明上文设计的文本分类模型的有效性，并且得到了中国专利文本分类的模型。传统的需要标注数据来训练的文本分类模型虽然在特定任务上的分类精准度高，但是往往需要大量的标注训练数据，及其依赖数据的质量和规模，并且标签固定，训练成本比如 GPU 资源需求高。

基于上述问题，本文亦采取了直接调用 DeepSeek-V3 大语言模型来实现专利文本分

中国知网 https://www.cnki.net

类的方案。这种方案可以通过灵活改变提示词动态调整分类规则并且零样本或者少样本需求，但是这种直接调用的方式依赖大模型的规模，输出不稳定，并且需要按照 Token 来付费。

LangChain 则是协调整合大模型 API、传统模型、工具链和外部数据的框架级方案。本文采用 LangChain 结合 DeepSeek-V3 实现了文本专利分类的方案。

最后，借助开源的 Python 库 Gradio 创建了一个模型的交互式界面，完成了三种技术方案的线上的模型推理部署工作，并且增设专利关键词提取模块。

6.2 未来展望

在进行本研究的各项任务时，出现了一些挑战和改进的空间，同时探索过程中也催生了一些新的研究思路，这些成果可为未来研究提供方向。

（1）数据集方面的完善。首先在本文第一个文本分类实验中，仅仅采用了清华大学学开源数据集 THUCNews 来验证所构建的新融合模型的有效性，数据集相对来说较为局限，后续需要在不同的大型公开数据集上进行进一步验证。其次在我国专利文本分类实验中，所采用的专利数据集规模相对较小，针对分类标签较少的分类任务分类效果较好，但在更细类别上的分类任务上分类效果较差。所以之后需要在更大数据集规模上做进一步研究。

（2）类别标签的进一步优化。本文是对专利数据进行分类实验，专利分类实际上属于多标签问题，本文只进行简单的单标签处理，并且在 IPC 分类中只进行第一步大类的分类工作，实际上 IPC 分类体系还存在多层多级别的分类，所以后续需要针对这分类标签问题做出更进一步的优化。

（3）中文专利文本分词系统。在文本分类中，对文本数据的分词是至关重要的一步，它直接影响着后续文本分类的效果。专利数据具有专业术语多、领域广的特点，大量专业术语的密集出现使得仅凭一般的分词工具和方法无法更好更精准的进行分词，这样势必会对分类结果产生影响。所以专门的中文专利文本数据分词系统的设计也为文本分类精度的提高提供了一个新方案。

（4）对中国专利文本分类系统的进一步完善。在本文中仅仅建立了一个相对较简单的文本分类系统，功能模块相对较少，后续会增设更多的专利分析研究交互模块。

（5）对 DeepSeek 大语言模型提示词技术的进一步完善和应用。本文考量到简便易行，只采用零样本学习（Zero-Shot）和简单的指令调优（Instruction Tuning）的提示词工程，后续会在多模态提示工程、对抗性提示和自动生成提示等方面进一步学习和应用。

（6）对 LangChain 框架流程架构的灵活设计。LangChain 是协调整合大语言模型

中国知网 https://www.cnki.net

API、传统模型、工具链和外部数据的框架级方案。本文仅结合了大语言模型 DeepSeek-v3 实现专利的分类，后续会结合领域知识，更加灵活编排分类流程，搭建混合分类架构。

中国知网 https://www.cnki.net

参考文献

[1] 邓乐平, 孙从海. 科技创新与资本市场—理论与经验的考察 [J]. 金融研究, 2001, (9): 11.

[2] 吴 汉, 胡 开. 走向知识经济时代的知识产权法 [J]. 2002.

[3] 孔嘉, 邓三鸿, 张佳锐, et al. 技术创新中的知识融合:"科学—技术"二元知识对专利影响研究 [J]. 情报学报, 2022, 41(11): 1161-1173.

[4] 夏芸, 马硕, 魏田苡薇. 创新磨刀石:企业战略激进度、数字化转型与技术篇局 [J]. 工业技术经济, 2024, 43(6): 140-149.

[5] 张燕舞, 情报科学 兰 J. 企业战略与竞争分析方法之一——专利分析法 [J]. 2003, 21(8): 3.

[6] 范威. 企业专利分级分类管理研究 [J]. 中国金属通报, 2022, (23): 152-155.

[7] 李小娟, 王双龙, 梁丽, et al. 基于专利价值分析体系的专利分级分类管理方法 [J]. 2014, (11): 4.

[8] 王艳领. 专利等级划分方法的研究与实现 [D]; 河北工业大学, 2010.

[9] 吕璐成, 韩涛, 周健, et al. 基于深度学习的中文专利自动分类方法研究 [J]. 图书情报工作, 2020, 64(10): 11.

[10] 马双刚. 基于深度学习理论与方法的中文专利文本自动分类研究 [D]; 江苏大学, 2016.

[11] 张晨. 专利检索新策略--关键词与分类号相结合 [J]. 科技情报开发与经济, 2014, (13): 112-113.

[12] 雷海卫, 李帆, 李成奇. 基于 ERNIE 的中文专利分类研究 [J]. 信息技术与信息化, 2023, (9): 116-119.

[13] 中国发明与专利 贾 J. 商业方法专利之 IPC 分类 [J]. 2006, (3): 2.

[14] 蒋健安. 面向专利文献数据的文本分类若干关键技术研究 [D]; 东南大学, 2008.

[15] 陈楠, 经济与管理研究 蔡 J. 人工智能技术创新与区域经济协调发展——基于专利数据的技术发展状况及区域影响分析 [J]. 2023, 44(3): 16-40.

[16] 陈家宏. 自动化分析专利范围的方法及专利分析系统, CN102135960A [P/OL].

[17] 徐雪洁, 王宝会. 基于文本及历史数据的多标签专利分类算法研究 [J]. 计算机科学, 2024, 51(5): 172-178.

[18] 张俊丽, 赵乃瑄, 冯君. 基于统计频率的文本分类特征选择算法研究 [J]. 现代图书

中国知网 https://www.cnki.net

情报技术, 2008, (11): 44-48.
[19] 赵耀军. 时间序列分析 [J]. 山西冶金, 2012, 35(6): 56-58.
[20] 喻海燕. 我国主权财富基金对外投资风险评估——基于三角模糊层次分析法(TFAHP)的研究 [J]. 厦门大学学报（哲学社会科学版）, 2015, (1): 110-118.
[21] 刘中涛, 陈龙, 黄万国, et al. 浅析专利分类在非专利文献检索中的应用 [J]. 中国发明与专利, 2012, (S1): 4.
[22] 杨大偲. 专利视角下长株潭知识创新能力评价研究 [D]; 湘潭大学.
[23] 李颖, 赵蕴华, 霍翠婷, et al. 日本专利检索体系中主题分类"FI/F-term"的理论与应用研究 [J]. 2008, 000(011): 11-17.
[24] Harris C G, Arens R, Srinivasan P J A. Comparison of IPC and USPC classification systems in patent prior art searches [J]. 2010: 27.
[25] 朱新超, 霍翠婷, 数字图书馆论坛 刘 J. 合作专利分类系统(CPC)与传统专利分类系统的比较分析 [J]. 2013, (9): 7.
[26] 廖佳佳, 高菲, 现代情报 吕 J. 联合专利分类体系研究 [J]. 2014, 34(1): 5.
[27] 朱雅琛, 黄非. CPC 分类体系:开创专利分类体系新纪元 [J]. 中国发明与专利, 2013, (2): 5.
[28] 于雷, 刘晓华. 浅议联合专利分类体系与实用新型评价报告的契合性 [J]. 科技与创新, 2019, (14): 5.
[29] 陈彦飞, 史凯. 输送领域专利文献的 CPC 分类体系 [J]. 2022, (17).
[30] 孙楚权. 基于 Transformer 的文本分类算法及应用 [D]; 山东工商学院, 2021.
[31]姜天宇, 王苏, 电脑知识与技术：学术版 徐 J. 基于朴素贝叶斯的中文文本分类 [J]. 2019, 15(8Z): 3.
[32] 张宁, 贾自艳, 计算机工程 史 J. 使用 KNN 算法的文本分类 [J]. 2005, 31(8): 3.
[33] 计算机工程与应用 奉 J. SVM 分类核函数及参数选择比较 [J]. 2011, 47(3): 3.
[34] 易晓婕, 钟志峰, 严诗玛, et al. 基于层权重融合与预测优化的中文短文本分类模型 [J]. 湖北大学学报(自然科学版).
[35] 何力, 郑灶贤, 项凤涛, et al. 基于深度学习的文本分类技术研究进展 [J]. 计算机工程, 2021, 47(2): 11.
[36] Hinton G, Deng L, Yu D, et al. Deep Neural Networks for Acoustic Modeling in Speech Recognition: The Shared Views of Four Research Groups [J]. 2012, 29(6): 82-97.
[37] Zaremba W, Sutskever I, Vinyals O J E A. Recurrent Neural Network Regularization [J]. 2014.
[38] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional

中国知网 https://www.cnki.net

Transformers for Language Understanding [J]. 2018.

[39] Spurek P, Danel T, Tabor J, et al. Geometric Graph Convolutional Neural Networks [J]. 2019.

[40] 宗成庆, 赵阳, 飞桨教材编写组. 《自然语言处理基础与大模型---案例与实践》 [J]. 中文信息学报, 2024, 38(3): F0003.

[41] Sun Y, Wang S, Li Y, et al. ERNIE: Enhanced Representation through Knowledge Integration [J]. 2019.

[42] 张德驰, 万卫兵. 掩码语言增强表示的对比学习微调和应用 [J]. 计算机工程与应用, 2024, 60(17): 129-138.

[43] Radford A, Narasimhan K. Improving Language Understanding by Generative Pre-Training [J]. 2018.

[44] DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning [J]. 2025.

[45] 唐琳, 郭崇慧, 陈静锋. 中文分词技术研究综述 [J]. 数据分析与知识发现, 2020, 4(2): 1-17.

[46] Hochreiter S, Schmidhuber J J N C. Long Short-Term Memory [J]. 1997, 9(8): 1735-1780.

[47] Mnih V, Heess N, Graves A, et al. Recurrent Models of Visual Attention [J]. 2014, 3.

[48] Sutton C, Mccallum A J F, Learning T i M. An Introduction to Conditional Random Fields [J]. 2010, 4(4): 267-373.

[49] 李超. 基于深度学习的中文分词方法研究 [D]; 辽宁工程技术大学, 2019.

[50] 江兆中. 基于语境和停用词驱动的中文自动分词研究 [D]; 合肥工业大学, 2010.

[51] 顾益军, 樊孝忠, 王建华, et al. 中文停用词表的自动选取 [J]. 北京理工大学学报, 2005, 25(4): 337-340.

[52] 陈靖元. 基于词语权重分析的中文文本相似检测技术研究 [D]; 郑州大学, 2021.

[53] 田瑞, 闫丹凤. 针对特定主题的短文本向量化 [J]. 软件, 2012, 33(11): 4.

[54] Bengio Y, Ducharme R j, Vincent P. A Neural Probabilistic Language Model [J]. 2001.

[55] Galke L, Scherp A. Bag-of-Words vs. Graph vs. Sequence in Text Classification: Questioning the Necessity of Text-Graphs and the Surprising Strength of a Wide MLP [J]. 2021.

[56] 施聪莺, 徐朝军, 计算机应用 杨 J. TFIDF 算法研究综述 [J]. 2009, 29(B06): 5.

[57] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space [J]. 2013.

[58] 于化鹏. 面向 Transformer 的量化技术研究 [D]; 郑州大学, 2023.

中国知网 https://www.cnki.net

[59] 曹志勇. 建模与优化中的特征变量降维与元模型技术研究 [D]; 华中科技大学, 2017.

[60] 张玲玲, 黄务兰. 基于 ChatGPT API 和提示词工程的专利知识图谱构建 [J]. 情报杂志, 2025, 44(3): 180-187.

[61] Sundberg L, Holmstrm J. Innovating by prompting: How to facilitate innovation in the age of generative AI [J]. Business Horizons, 2024, 67(5): 561-570.

[62] 孙斐. 大模型提示词工程的进展,综述及展望 [J]. 计算机应用文摘, 2024, 40(18): 179-182.

[63] 季东霖, 郭子浩, 陈雨洁, et al. 对比经微调的 ERNIE-Lite-8K-0922 和 GPT-4 在使用 Prompt 策略后在英语对话系统中的表现:以心理咨询师角色为例 [J]. 人工智能与机器人研究, 2024, 13(2): 272-281.

[64] 刘珏, 赵辉, 陈晨, et al. 一种基于专家模型辅助的大模型提示词工程方法及系统, CN118982070A [P/OL].

[65] 陆伟, 刘寅鹏, 石湘, et al. 大模型驱动的学术文本挖掘--推理端指令策略构建及能力评测 [J]. 情报学报, 2024, (8).

[66] 窦凤岐, 胡珊, 李佳隆, et al. 基于 LangChain 的 RAG 问答系统设计与实现——以 C 语言课程问答系统为例 [J]. 信息与电脑, 2024, 36(6): 101-103.

[67] Cardenas O, Falconi S, Tusa E R A. Development of a ChatBot model for health telecare: Integration of LangChain, embeddings with OpenAI, and Pinecone using the question answering technique [J]. Journal of Applied Research and Technology, 2024, 22(3): 389-402.

[68] Easin Arafat M, Asuah G, Saha S, et al. Empowering Real-Time Insights Through LLM, LangChain, and SAP HANA Integration; proceedings of the The International Conference on Recent Innovations in Computing, F, 2024 [C].

[69] Workman A D, Rathi V K, Lerner D K, et al. Utility of a LangChain and OpenAI GPT - powered chatbot based on the international consensus statement on allergy and rhinology: Rhinosinusitis [J]. International Forum of Allergy & Rhinology, 2024, 14(6).

[70] Jaiswal A, Tiwari G, Jha A, et al. Retrieval Augmented Generation Approach for Multipdf Chatbot using LangChain; proceedings of the 2024 8th International Conference on Computing, Communication, Control and Automation (ICCUBEA), F].

[71] 陈迪欢, 陆希, 张耀峰. 基于 LangChain+LLM 的招投标领域问答系统研究 [J]. 大数据时代, 2024, (5): 23-28.

[72] Kim Y J E A. Convolutional Neural Networks for Sentence Classification [J]. 2014.

中国知网 https://www.cnki.net

[73] Liu P, Qiu X, Huang X J A P. Recurrent Neural Network for Text Classification with Multi-Task Learning [J]. 2016.

[74] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation [J]. 2014.

[75] <Recurrent Convolutional Neural Networks for Text Classification.pdf> [J].

[76] Johnson R, Zhang T. Deep Pyramid Convolutional Neural Networks for Text Categorization; proceedings of the Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), F, 2017 [C].

[77] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need [J]. 2017.

[78]于强, 林民, 李艳玲. 基于深度学习的关键词生成研究综述 [J]. 计算机工程与应用, 2022, 58(14): 13.

[79] 计算机科学与技术. 面向中文文本的对抗攻击与防御关键技术研究 [D], 哈尔滨工程大学, 2023.

[80] 张雪凯. 基于Transformer的双向编码表征模型的语义关系抽取方法研究 [D]; 河南大学, 2021.

[81] 陈航. 基于 BERT 和迁移学习的业务流程预测与可解释性研究 [D]; 安徽理工大学, 2023.

[82] 宋瑞. 面向预训练语言模型文本分类捷径学习问题的缓解技术研究 [D]; 吉林大学, 2024.

[83] Sun Y, Wang S, Li Y, et al. ERNIE 2.0: A Continual Pre-Training Framework for Language Understanding, F, 2020 [C].

[84] Sun Y, Wang S, Feng S, et al. ERNIE 3.0: Large-scale Knowledge Enhanced Pre-training for Language Understanding and Generation [J]. 2021.

[85] 张博旭. 基于改进预训练模型的短文本文本分类的研究与实现 [D]; 新疆农业大学, 2023.

[86] DeepSeek-AI, Liu A, Feng B, et al. DeepSeek-V3 Technical Report [J/OL] 2024, arXiv:2412.19437[https://ui.adsabs.harvard.edu/abs/2024arXiv241219437D.10.48550/arXiv.2412.19437

[87] Dai D, Deng C, Zhao C, et al. DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models [J/OL] 2024, arXiv:2401.06066[https://ui.adsabs.harvard.edu/abs/2024arXiv240106066D.10.48550/arXiv.2401.06066

[88] DeepSeek-AI, Liu A, Feng B, et al. DeepSeek-V2: A Strong, Economical, and Efficient

中国知网 https://www.cnki.net

Mixture-of-Experts Language Model [J/OL] 2024, arXiv:2405.04434[https://ui.adsabs.harvard.edu/abs/2024arXiv240504434D.10.48550/arXiv.2405.04434

[89] 尹新天. 新专利法详解 [M]. 新专利法详解, 2001.

[90] 付济宇. 专利开放许可制度完善研究 [D]; 上海财经大学, 2022.

[91] 耿宾. 发明专利的多维度评价 [J]. 法制博览, 2024, (29): 46-48.

[92] 实用新型专利 [J]. 中国皮革, 2012, 41(14): 124-125.

[93] 武楫凯. 局部外观设计专利侵权认定研究 [D]; 河北经贸大学, 2024.

[94] 国家知识产权局. 国家知识产权局年报 [Z]. 2024

[95] 王兴旺. 专利竞争态势分析:类型、内容及方法述评——兼论我国的研究现状 [J]. 现代情报, 2017, 37(11): 171-177.

[96] 曾鹏, 赵聪. 中国三种类型专利密度分布时空差异研究 [J]. 科技进步与对策, 2016, 33(21): 117-125.

[97] 温芳芳. 基于专利权人-分类号耦合分析的潜在合作关系网络研究 [J]. 情报学报, 2016, 35(12): 1265-1272.

[98] 徐倩. 基于社会网络分析的专利权人关联网络研究 [D]; 中国农业科学院, 2019.

[99] 刘少芳. 基于专利权人视角的全球区块链技术专利发展态势分析 [J]. 科技和产业, 2019, 19(8): 120-124.

[100]顾震宇. 基于案例分析的区域专利分析方法应用研究 [J]. 情报杂志, 2010, 29(8): 40-44.

[101]陈荣, 李建辉, 孙济庆. 基于专利信息分析的区域技术创新能力研究 [J]. 科技与经济, 2013, 26(2): 36-40.

[102]陈楠, 蔡跃洲. 人工智能技术创新与区域经济协调发展——基于专利数据的技术发展状况及区域影响分析 [J]. 经济与管理研究, 2023, 44(3): 16-40.

[103] 国家知识产权局. 2024 年中国专利调查报告 [Z]. 2025: https://www.cnipa.gov.cn/module/download/down.jsp?i_ID=197320&colID=197388

[104]专利文献出版社. 国际外观设计分类表:大类和小类表及产品目录表 [M]. 国际外观设计分类表:大类和小类表及产品目录表, 1986.

[105]胡玉兰, 赵青杉, 陈莉, et al. 面向中文新闻文本分类的融合网络模型 [J]. 中文信息学报, 2021.

[106]李荣陆. 文本分类及其相关技术研究 [D], 复旦大学, 2005.

[107]张文军, 冯永军, 古德祥. 统计显著性标记的聚类分析算法与网络实现 [J]. 数值计算与计算机应用, 2005, 26(3): 9.

中国知网 https://www.cnki.net

[108]Sun Z, Zhang X, Xue Y, et al. [Effects of recombinant human granulocyte macrophage colony stimulating factor gel on treatment of full-thickness frostbite wounds on foot and hand] [J]. Zhonghua shao shang za zhi = Zhonghua shaoshang zazhi = Chinese journal of burns, 2020, 36(2): 117-121.

[109]杨业兵, 苗丹民, 田建全, et al. 人格测验的变异性及效应量分析 [J]. 中国行为医学科学, 2007, 16(10): 2.

[110]王倩. 基于相似文档的关键词自动提取研究 [D]; 武汉大学, 2019.

中国知网 https://www.cnki.net